Strojno učenje 1

Sažetak

Prof. dr. sc. Jan Šnajder

Ak. god. 2025./2026.

Plan

1. Osvrt
2. Kako dalje?

Plan

1. Osvrt
2. Kako dalje?

Plan nastave

- Uvod u strojno učenje
- Osnovni koncepti, regresija
- Linearni diskriminativni modeli, logistička regresija
- Stroj potpornih vektora, jezgrene funkcije, neparametarski modeli
- Opcionalno: Ansambli

  Međuispit
- Procjena parametara
- Bayesov klasifikator i probabilistički grafički modeli
- Grupiranje
- Vrednovanje modela
- Opcionalno: Odabir značajki

  Završni ispit

Ishodi učenja

- definirati osnovne pojmove strojnog učenja
- objasniti teorijske pretpostavke, matematičke osnove te prednosti i nedostatke temeljnih algoritama nadziranog i nenadziranog strojnog učenja
- primijeniti temeljne algoritme klasifikacije, regresije i grupiranja na jednostavnije probleme
- primijeniti postupak odabira modela i evaluacije točnosti naučenog modela
- analizirati i usporediti temeljne algoritme strojnog učenja s obzirom na njihove komponente i računalnu složenost
- razlikovati temeljne pristupe strojnom učenju (generativni/diskriminativni, parametarski/neparametarski, bayesovski/frekventistički) te objasniti poveznice
- procijeniti prikladnost temeljnih algoritama strojnog učenja za zadani zadatak
- oblikovati i implementirati jednostavnije algoritme za klasifikaciju, regresiju i grupiranje

U konačnici, želimo da...

1. Razumijete **osnovne ideje** i **razine apstrakcije**
2. Razumijete tipičnu **matematiku** ispod toga
3. Shvatite **algoritme i metode** tako da ih implementirate ili ispitate na jednostavnim primjerima
4. Izgradite svoju **kartu područja** i dobijete **putokaze** za samostalno učenje

Izvođači

Predavači:

- Prof. dr. sc. Jan Šnajder
- Prof. dr. sc. Stjepan Picek
- Izv. prof. dr. sc. Marko Đurasević

Asistenti:

- Josip Jukić, mag. ing. (glavni asistent)
- Ana Barić, Ivan Bilić, Marko Čuljak, Karlo Koledić, Josipa Lipovac

Demosi:

- Alan Đurđević, Ana Vuksanović, Andrea Milanović, Dora Bilić-Pavlinović, Dunja Petrović, Filip Vučenik, Fran Širić, Hana Ivančić, Ivan Skukan, Jelena Lončar, Lana Barišić, Lana Ćorić, Petar Belošević, Vedran Ćutić, Vedran Knežević, Vinko Đurić

Plan

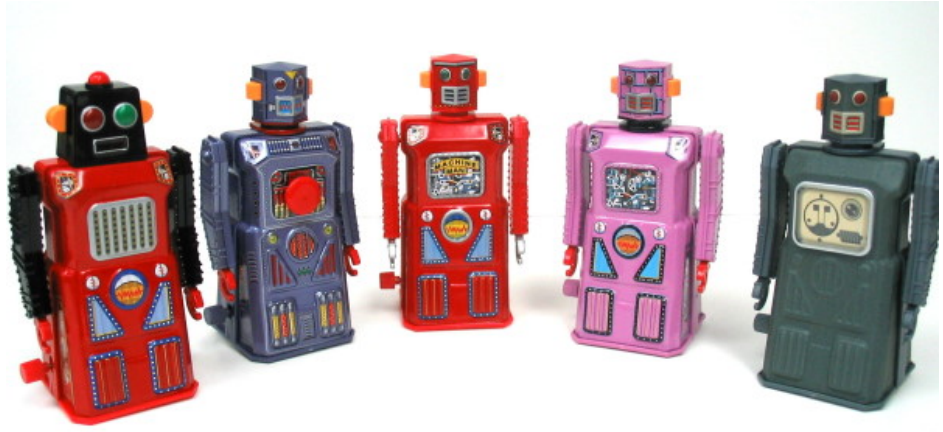
1. Osvrt
2. Kako dalje?

Kako dalje?

- Položite završni :-)
- Imate vrlo dobre osnove iz SU, čak i ako zaboravite detalje!
- U praktičnom smjeru:
  - razmislite gdje u svojem radu (diplomski rad?) možete upotrijebiti metode strojnog učenja
  - implementirajte sustav (možete se osloniti na postojeće alate)
  - napravite ispravno vrednovanje sustava (unakrsna provjera!)
- U teorijskom smjeru:
  - naučite teme koje nismo stigli obraditi
  - kompletno pročitajte jedan udžbenik iz strojnog učenja
  - produbite svoje znanje učenjem naprednijih tema koje vas zanimaju
  - kada postanete suvereni u nekoj temi, počnite čitati znanstvene članke

Pet škola strojnog učenja

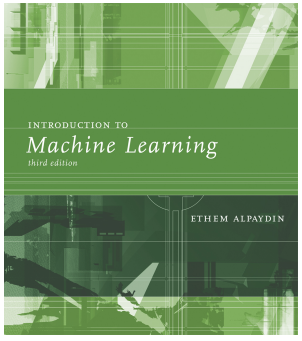
Pedro Domingos: The Master Algorithm



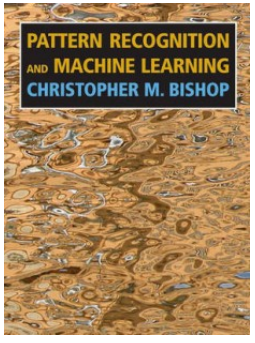
Škola	Temelji	Glavni algoritam
Symbolists	Logika, filozofija	Indukcija
Connectionists	Neuroznanost	Backpropagation
Evolutionaries	Evolucijska biologija	Genetičko programiranje
Bayesians	Statistika	Probabilističko zaključivanje
Analogizers	Psihologija	Jezgreni strojevi

Literatura

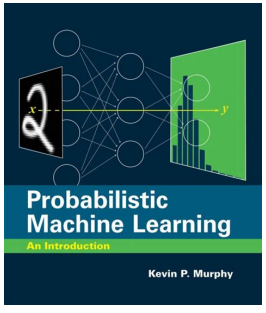
- Ethem Alpaydin:
  Introduction to Machine Learning,
  3rd edition, MIT Press, 2015.



- Christopher Bishop:
  Pattern Recognition and Machine Learning,
  Springer, 2006.



NEW Kevin P. Murphy: *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.



Dodatna dodatna literatura

Osnovno:

- Hastie, Tibshirani, Friedman: *Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2003.
- Deisenroth, Faisal, Ong: *Mathematics for Machine Learning*. Cambridge University Press, 2020.
- Marsland: *Machine Learning: An Algorithmic Perspective*, Chapman and Hall/CRC, 2009.
- Duda, Hart, Stork: *Pattern Classification*, Wiley-Interscience, 2000.

Napredno:

- Murphy: *Probabilistic Machine Learning: Advanced Topics*, MIT Press, 2022.
- Mohri, Rostamizadeh, Talwalkar: *Foundations of Machine Learning*, MIT Press, 2012.
- Shalev-Shwartz, Ben-David: *Understanding machine learning: From theory to algorithms*, Cambridge University Press, 2014.

Specifično:

- Koller, Friedman: *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- Goodfellow, Bengio, Courville:*Deep Learning*, MIT Press, 2016.

Vruće teme?

- Duboko učenje (generativni AI, difuzijski modeli, transformatori, GNN)
- Podržano učenje (reinforcement learning, deep reinforcement learning)
- Samonadzirano učenje (self-supervised learning)
- Kauzalno strojno učenje
- Multimodalno učenje
- Sigurnost i privatnost u SU
- Robusnost i interpretabilnost
- ...

- Videopredavanja na videolectures.net
- Tutoriali na konferencijama NeurIPS i ICML
- Podcast: Machine Learning Street Talk
- Ljetne škole (MLSS, ESSLLI, ...)

Srodni predmeti na FER-u

- Analiza i pretraživanje teksta (2)
- Analiza velikih skupova podataka (2)
- Dubinska analiza podataka (2)
- Duboko učenje 1 (2)
- Duboko učenje 2 (3)
- Ekspertni sustavi (2)
- Meko računarstvo (1)
- Multivarijatna analiza podataka (2)
- Neuronske mreže (1, 3)
- Optimiranje evolucijskim računanje (1, 3)
- Poslovna inteligencija (2)
- Računarska statistika (2)
- Raspoznavanje uzoraka (1, 3)
- Strojno učenje 2 (3)
- Statistička analiza podataka (1)
- Uvod u znanost o podatcima (1)

Analiza i pretraživanje teksta (TAR)

http://www.fer.unizg.hr/predmet/apt

Većina ljudskog znanja pohranjena je u **nestrukturiranom, tekstnom obliku**. Zbog ogromne i rastuće količine digitalnih tekstnih podataka, sustavi za **analizu i pretraživanje teksta** postali su neizostavan dio suvremene informacijsko-komunikacijske infrastrukture. Zbog složenosti i višeznačnosti prirodnog jezika, analiza teksta netrivijalan je zadatak, koji se oslanja na postupke **obrade prirodnog jezika**, **računalne lingvistike** i **strojnog učenja**. Ovaj predmet daje cjelovit pregled tradicionalnih i naprednih postupaka za analizu i pretraživanje teksta, uključivo postupka temeljenih na statističkoj obradi jezika i strojnome učenju.

- Predmet se predaje isključivo na **engleskome jeziku**
- U drugom dijelu predmeta čitaju se i diskutiraju **znanstveni članci**
- Rade se **projekti** koji se prezentiraju ih u obliku znanstvenog rada

Strojno učenje 2

- Kako osigurati da model dobro generalizira? $\Rightarrow$ teorija statističkog strojnog učenja (SLT)
- Kolegij daje uvod u teoriju statističkog učenja i pregled primjena na klasične i moderne algoritme strojnog učenja
- Dio 1: Osnovni koncepti i alati teorije statističkog učenja
- Dio 2: Primjena na klasične klasifikacijske i regresijske algoritme
- Dio 3: Naprednije tehnike teorije statističkog učenja i primjene na modele dubokog učenja

- Teorijski predmet (teoremi i dokazi)
- Predavanja moguće (po odluci većine) na engleskom jeziku
- Intenzivne pripreme za svako predavanje + zadaće + studentske prezentacije
- Ograničenje na broj studenata

Hvala!