Strojno učenje 1

1. Uvod u strojno učenje

Prof. dr. sc. Jan Šnajder

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva

Ak. god. 2025./2026.

v3.5

Sadržaj

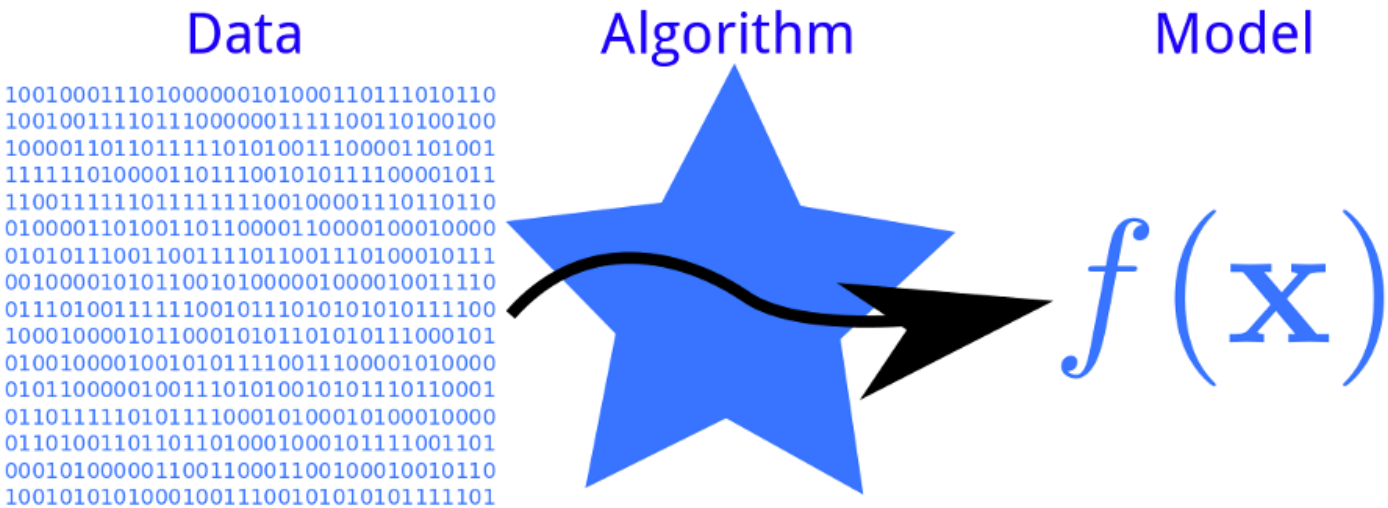
1. Što i zašto?
2. Pristupi strojnom učenju
3. Organizacija predmeta

Motivacija

- "We are drowning in data, but we are starved for knowledge"
  – John Naisbitt, *Megatrends*
- Podatci = sirove informacije
- Znanje = uzorci u podatcima ili modeli koji ih objašnjavaju



Strojno učenje



- Algoritmi za (polu)automatsku ekstrakciju novog i korisnog znanja – u obliku **pravila, uzoraka ili modela** – iz proizvoljnih skupova podataka

Strojno učenje

Strojno učenje (Alpaydin 2009)

Strojno učenje je programiranje računala na način da optimiziraju neki kriterij uspješnosti temeljem podatkovnih primjera ili prethodnog iskustva.

- Raspolažemo modelom koji je definiran do na neke parametre
- Učenje: optimizacija parametara modela temeljem podataka
- Na temelju viđenih podataka, model mora moći predvidjeti svojstva novih, još neviđenih podataka
- Cilj strojnog učenja: izgraditi modele koji dobro generaliziraju

Interdisciplinarnost strojnog učenja

- Umjetna inteligencija
- Teorija vjerojatnosti
- Statistika
- Optimizacija
- Teorija informacije
- Teorijska računarska znanost
- Baze podataka
- Pretraživanje informacija (engl. *information retrieval*)
- Psihologija, neurobiologija, kognitivna znanost

Svi putevi vode k. . . strojnom učenju

- **Matematika: statistika**
  - 17. stoljeće: Vjerojatnost
  - 18. stoljeće: Prvi Bayesovski pristupi
  - 20. stoljeće: Frekventisti
  - 1980.: Značajan razvoj Bayesovskih pristupa (MCMC)
- **Elektrotehnika: Obrada signala**
  - Početci u drugome svjetskom ratu
  - 1960.–1970.: FFT, projektiranje filtara
  - 1980.–1990.: Očitavanje signala, obrada slike

Svi putevi vode k. . . strojnom učenju

- **Računarstvo: UI**
  - 1940.: Perceptron
  - 1960.–1970.: Logičko programiranje
  - 1980.: Backpropagation, PAC, Bayesove mreže
  - 2000.+: SVM, PGM, Transfer learning, Structured learning, Online learning, Deep learning, . . .
- **Računarstvo: Razne komplementarne ideje**
  - Baze podataka: Dubinska analiza podataka, statističke baze podataka (OLAP), probabilističke baze podataka
  - Pretraživanje informacija: PageRank
  - Računalni sustavi: MapReduce, Hadoop

Strojno učenje danas

Broj radova na SU konferencijama

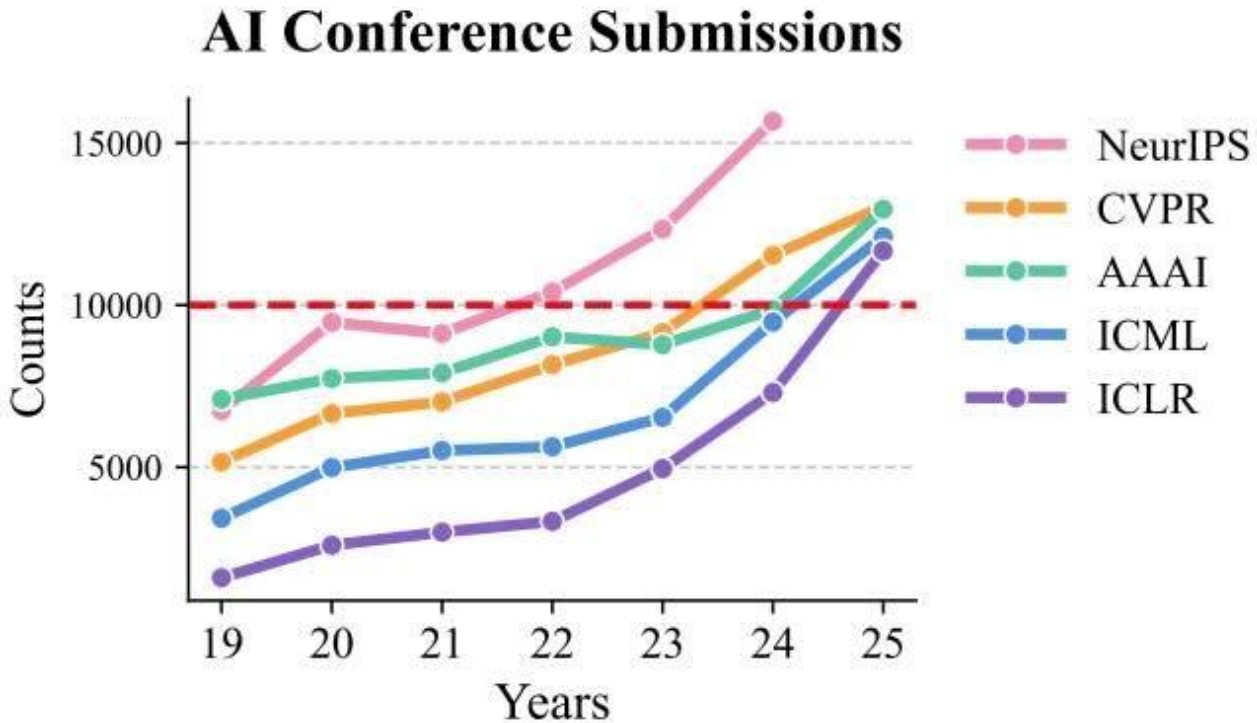


Figure 1: AI Conference Submission Counts. The number of paper submissions to most major AI conferences (*e.g.* NeurIPS, CVPR, AAAI, ICML, ICLR) exceeded 10,000 by 2025. For example, there was a 59.8% increase in ICLR submissions in 2025 alone. We forecast similar growth in other venues as well.

https://arxiv.org/pdf/2505.04966

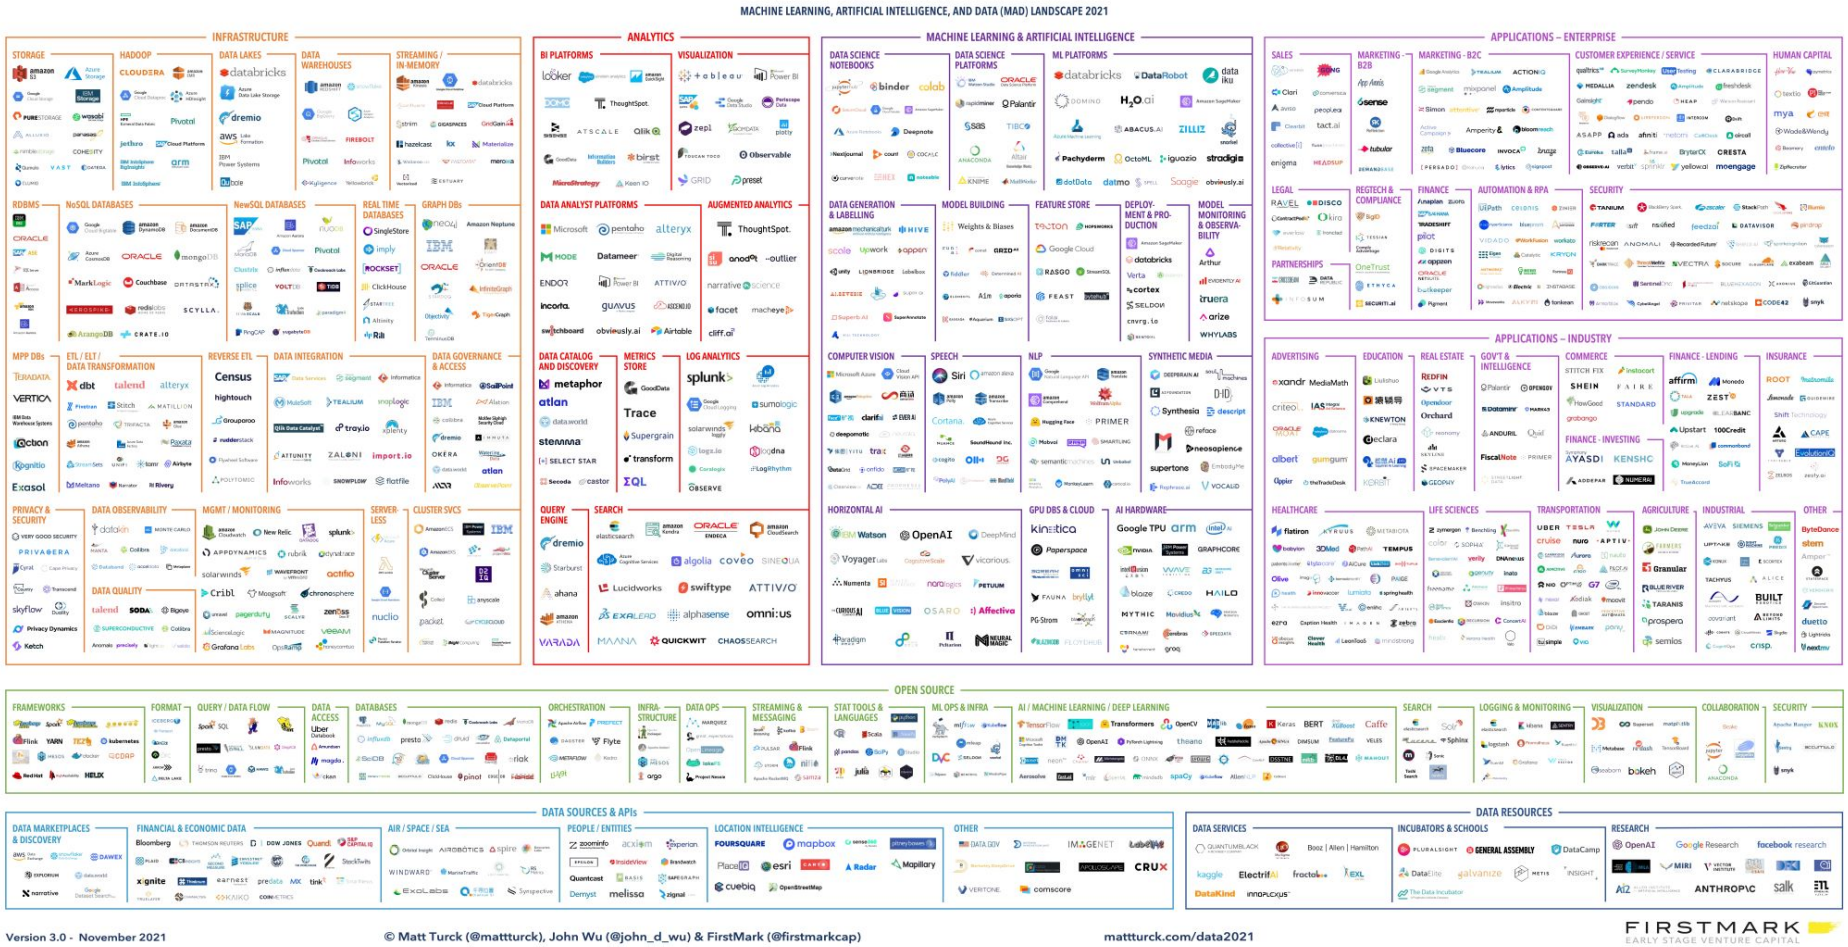
Također strojno učenje danas

Hokus pokus

5.1. Dataset

As we know Deep Neural Networks are data intensive and it performs better if trained with a dataset with large amount of data. As dataset in Bangla language is publicly not available, we collect about 850 Bangla comments from different sources and process them to make them suitable to train the network. Among the comments, 500 comments are positive and the rests are negative. But as the amount of comments is not sufficient to train our proposed network, we just copy-paste the comments repeatedly to increase the size of our dataset. We increase the number of comments in our dataset approximately to 120000. Where 60000 comments are positive and 60000 comments are negative. We divide the positive and negative comments into separate files. To evaluate the model at training period we use 10-fold cross-validation on the training data.

Krajolik alata strojnog učenja



https://mattturck.com/data2021/

Primjene strojnog učenja

1. **Složeni problemi** – ne postoji ljudsko znanje o procesu ili ljudi ne mogu dati objašnjenje procesa (npr. raspoznavanje govora)
   - problemi koje nije moguće riješiti na klasičan algoritamski način *(UI-potpuni problemi)*
2. **Sustavi koji se dinamički mijenjaju**
3. **Ogromne količine podataka** – ima li znanja u njima?
   - otkrivanje znanja u skupovima podataka (engl. *data mining*)

Slučaj 1: Teški problemi

- Raspoznavanje uzoraka
- Računalni vid
- Obrada prirodnog jezika
- Raspoznavanje govora
- Robotika
- ...



Slučaj 2: Dinamički prilagodivi sustavi

- Inteligentni računalni sustavi moraju se moći **prilagoditi svojoj okolini**
- Sustav koji je sposoban učiti može se bolje prilagoditi novim situacijama



- Robotika
- Višeagentni sustavi
- Inteligentna korisnička sučelja
- . . . ali zapravo bilo kakav inteligentni agent (računalni program koji djeluje u pravoj ili stvarnoj okolini, npr., virtualni asistent, algoritam za igru Go, dron za spašavanje. . .)

Slučaj 3: Od podataka do znanja

- Podatci $\rightarrow$ informacije $\rightarrow$ znanje $\rightarrow$ odluka
- **Podataka** ima u izobilju (web, tekst, eksperimentalni podatci, skladišta podataka *deep web*, *logovi*)
- S druge strane, **znanja** nema puno i ono je skupo
- Cilj: izgradnja modela koji objašnjavaju podatke i omogućavaju zaključivanje/predviđanje

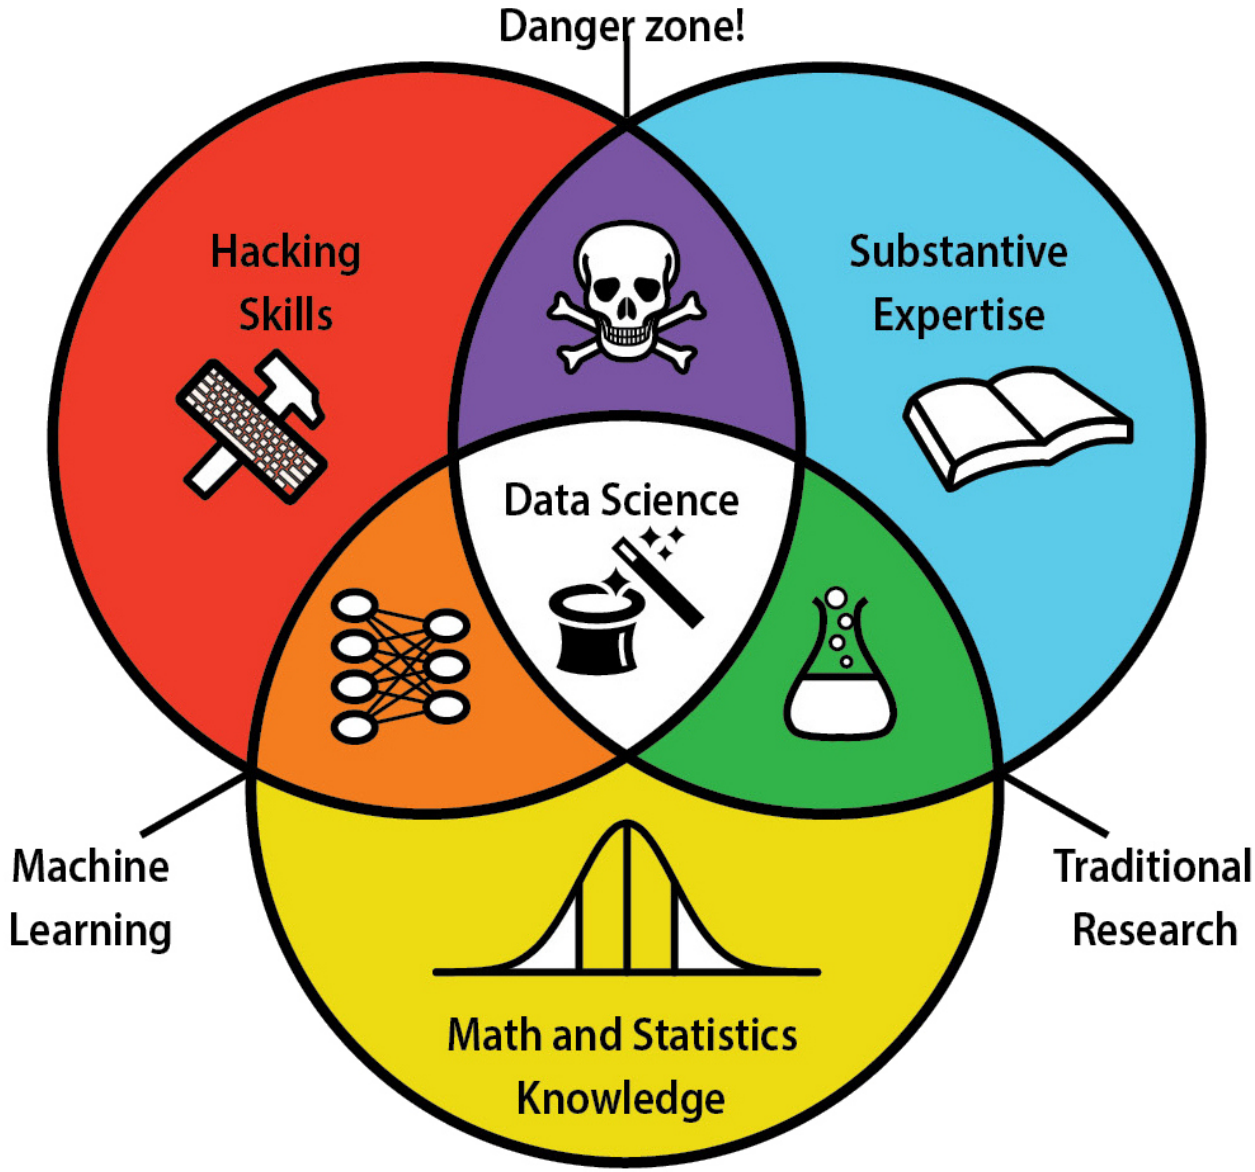


Dubinska analiza podataka

Dubinska analiza podataka (engl. *data mining*) ili **otkrivanje znanja u skupovima podataka** (engl. *knowledge discovery in datasets*) – primjena strojnog učenja na (polu)strukturirane baze podataka

- Prodaja: analiza potrošačke košarice, CRM
- Financije: određivanje kreditne sposobnosti, detekcija zlouporaba kartica
- Proizvodnja: optimizacija, *troubleshooting*
- Medicina: postavljanje dijagnoza, prevencija
- Telekomunikacije: optimizacija usluga
- Bioinformatika: analiza izražajnosti gena, poravnavanje gena
- Text mining: klasifikacija teksta, ekstrakcija informacija
- ...

Znanost o podatcima (engl. *Data Science*)



http://berkeleysciencereview.com/how-to-become-a-data-scientist-before-you-graduate/

Sadržaj

1 Što i zašto?

2 Pristupi strojnom učenju

3 Organizacija predmeta

Tri pristupa strojnom učenju

(1) Nadzirano učenje (engl. *supervised learning*)

Podatci su parovi *(ulaz, izlaz)*$=(x, y)$, treba pronaći $\hat{y} = f(x)$

- Ako je y je diskretna/nebrojčana vrijednost: klasifikacija
- Ako je y kontinuirana/brojčana vrijednost: regresija

(2) Nenadzirano učenje (engl. *unsupervised learning*)

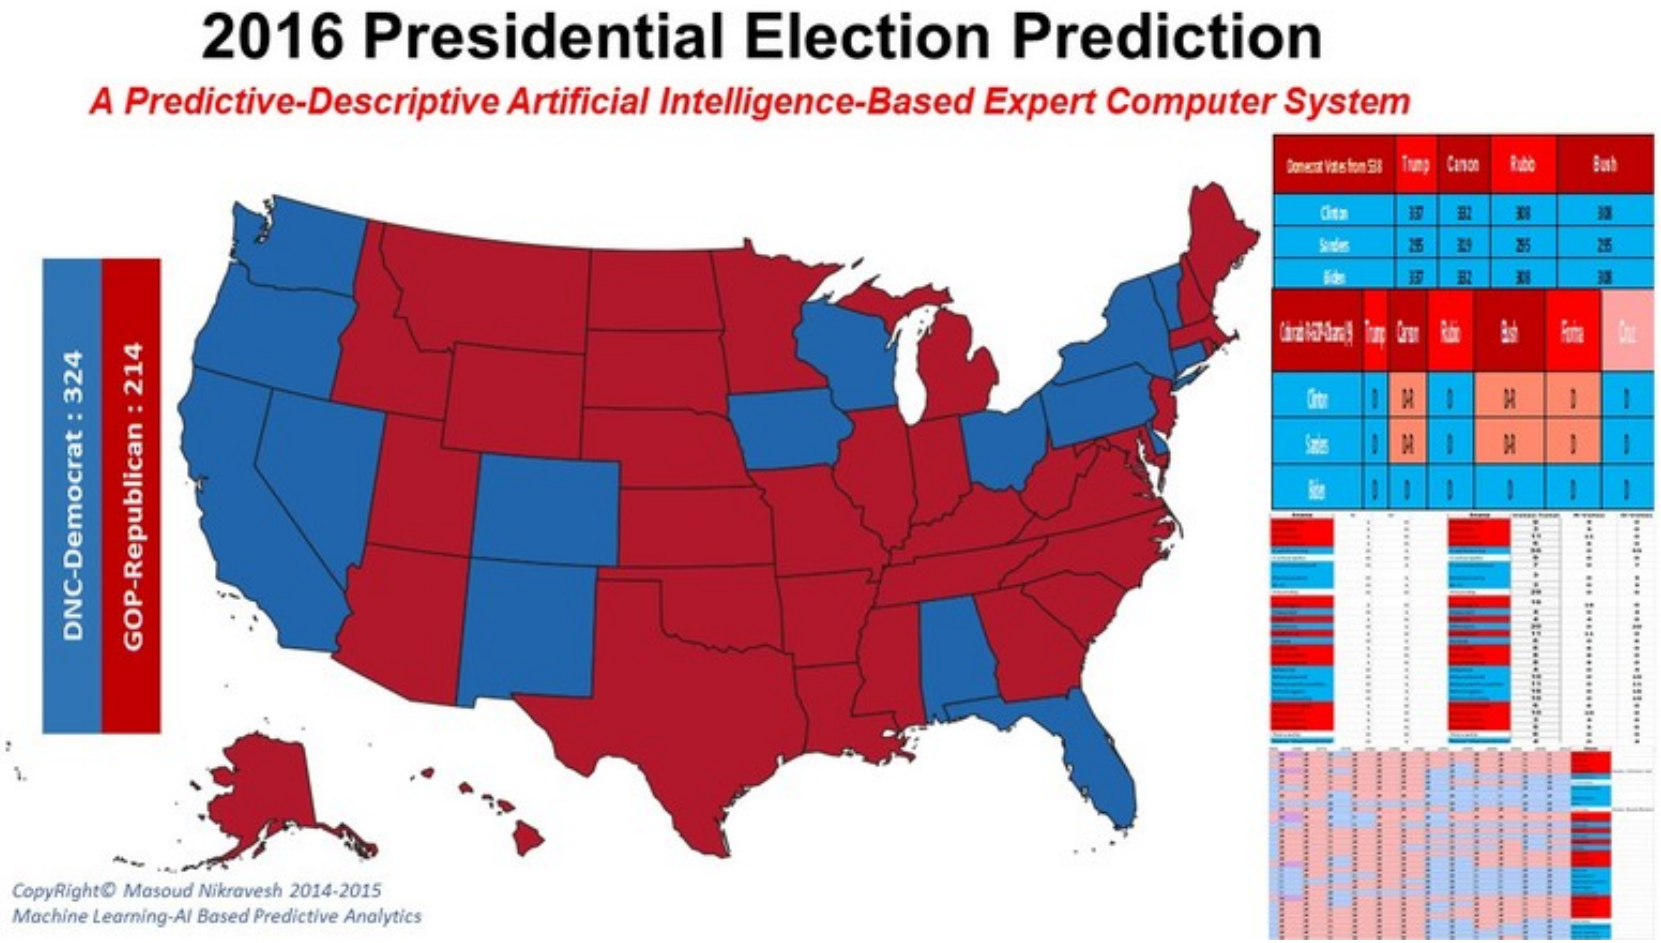
Dani su podatci bez ciljne vrijednosti, treba naći pravilnost u podatcima

- grupiranje (engl. *clustering*)
- procjena gustoće (engl. *density estimation*)
- smanjenje dimenzionalnosti (engl. *dimensionality reduction*)

(3) Podržano/ojačano učenje (engl. *reinforcement learning*)

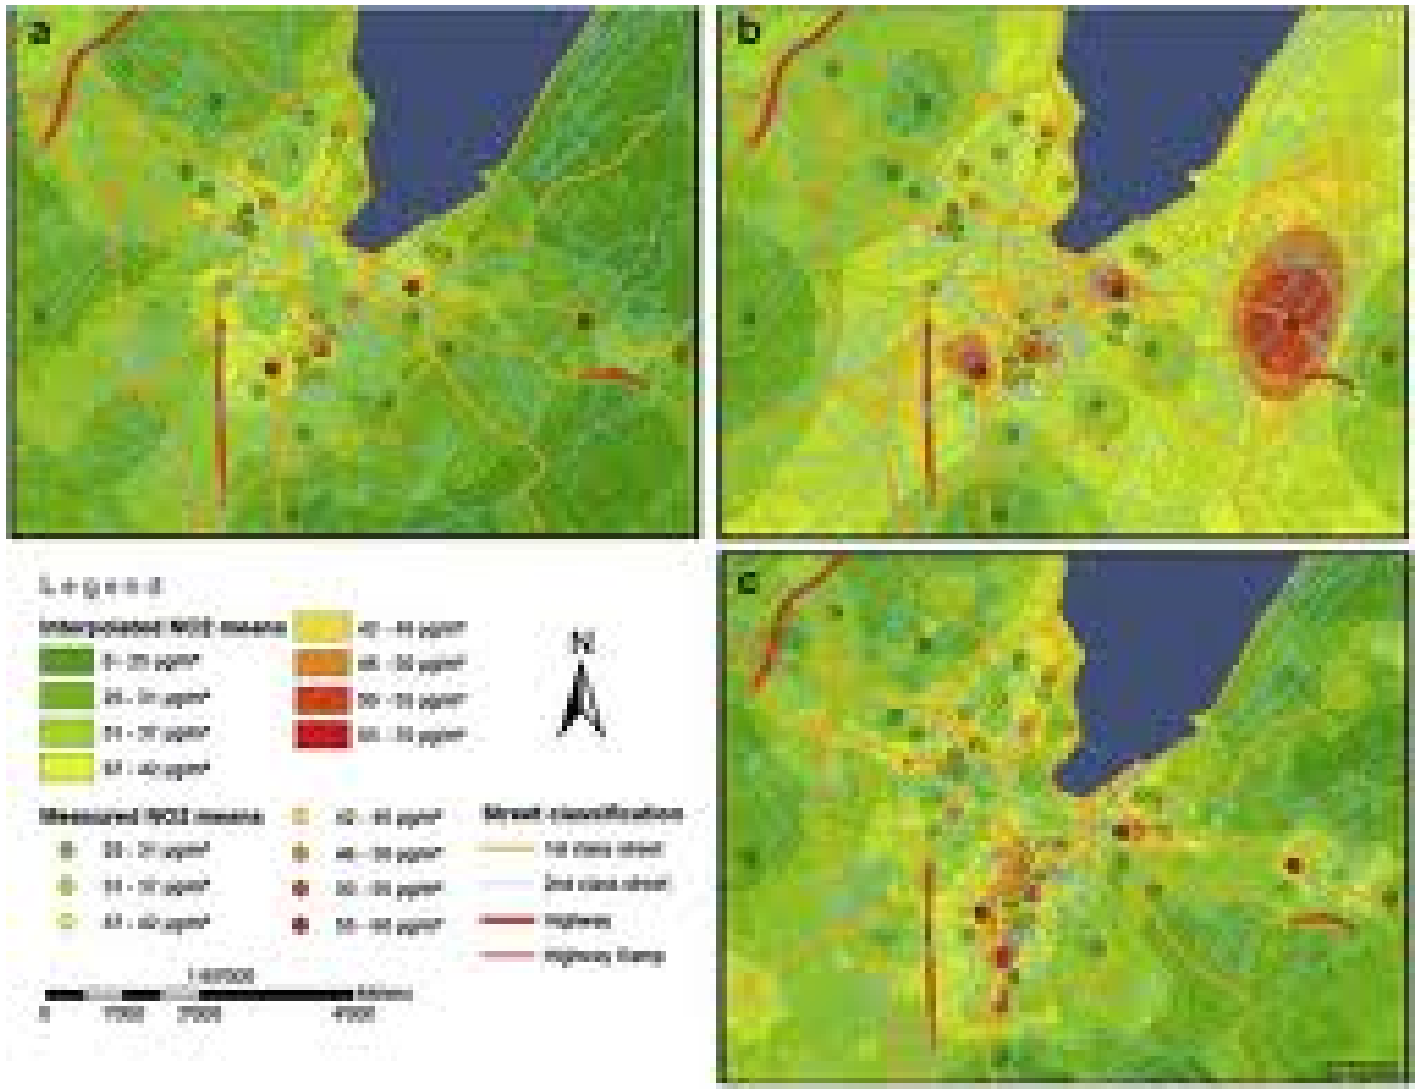
Učenje optimalne strategije na temelju pokušaja s odgođenom nagradom

Primjena klasifikacije: predviđanje ishoda izbora



Election Analytics (https://www.experfy.com/uploads/ckeditor/pictures/132/content_NikraveshSlide3.JPG)

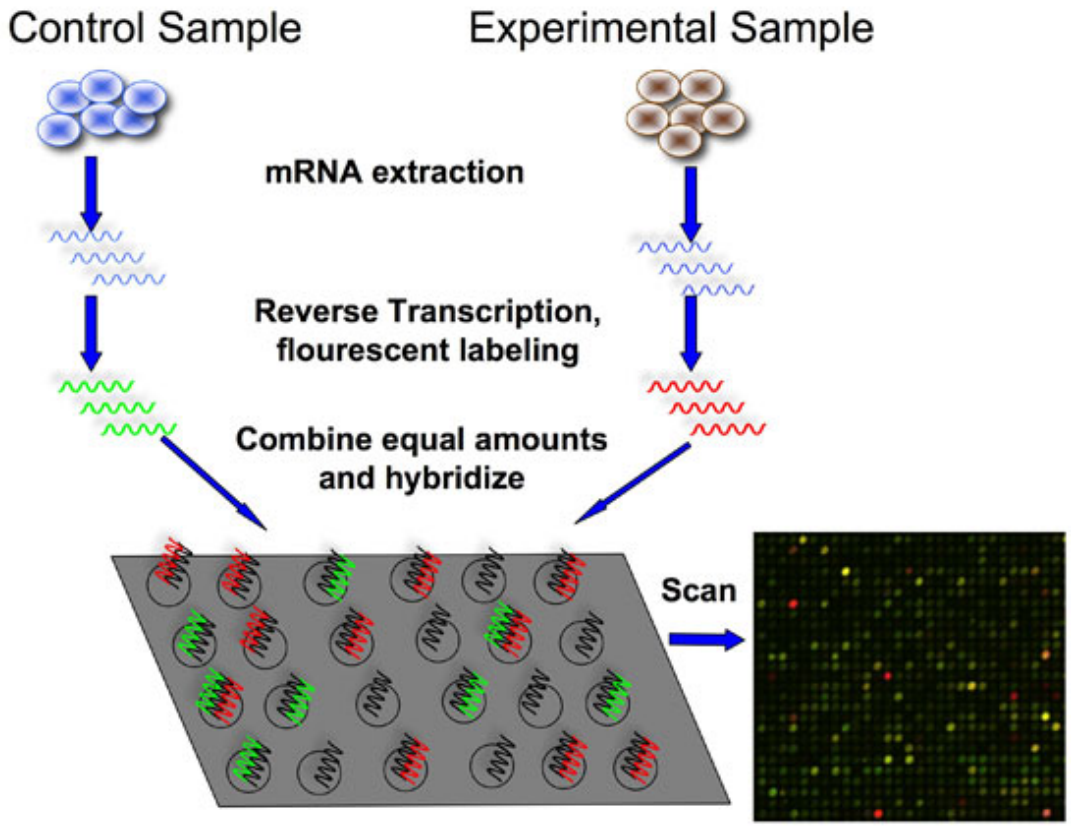
Primjena regresije: predviđanje razine emisije NO_2

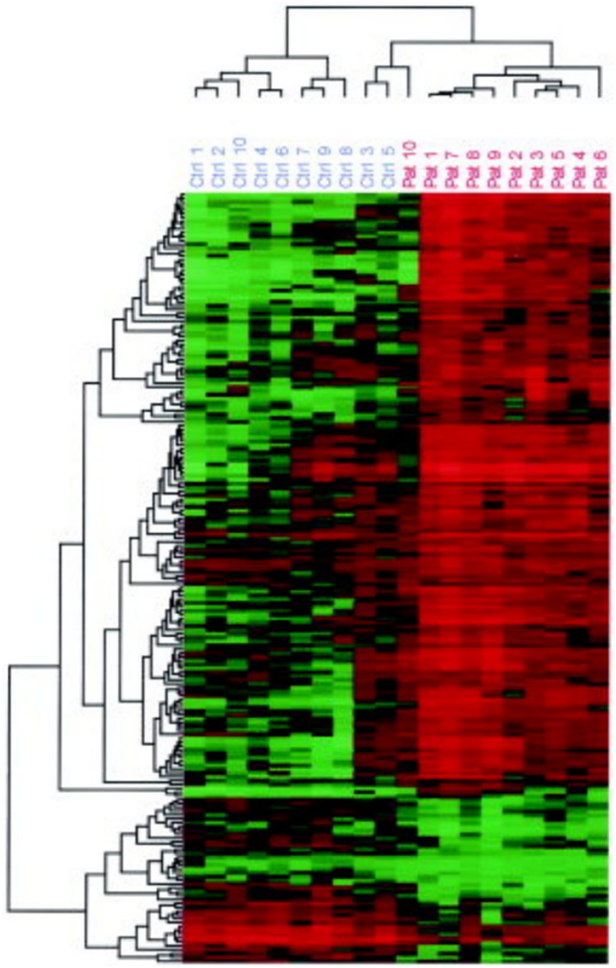


Exposure models for traffic related NO2 (http://www.sciencedirect.com/science/article/pii/S1352231011009629)

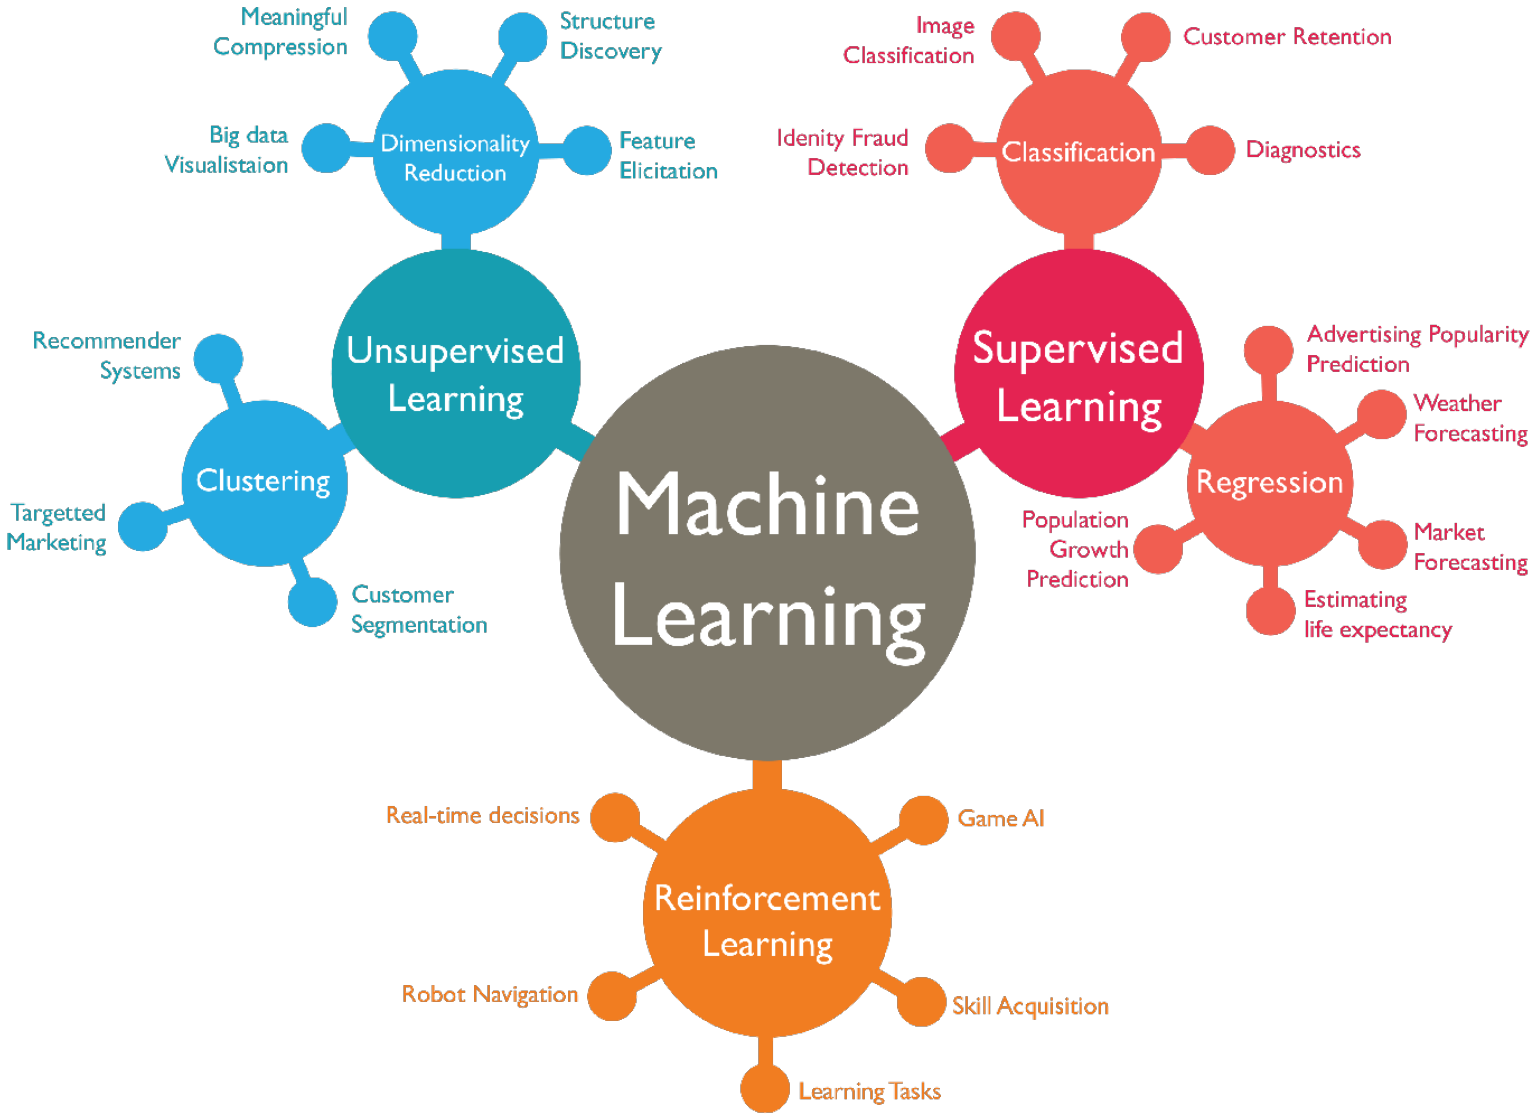
Primjena grupiranja: analiza DNK-mikropolja

Cilj: grupiranje gena sa sličnom izražajnošću
(slična izražajnost – slična funkcionalnost)



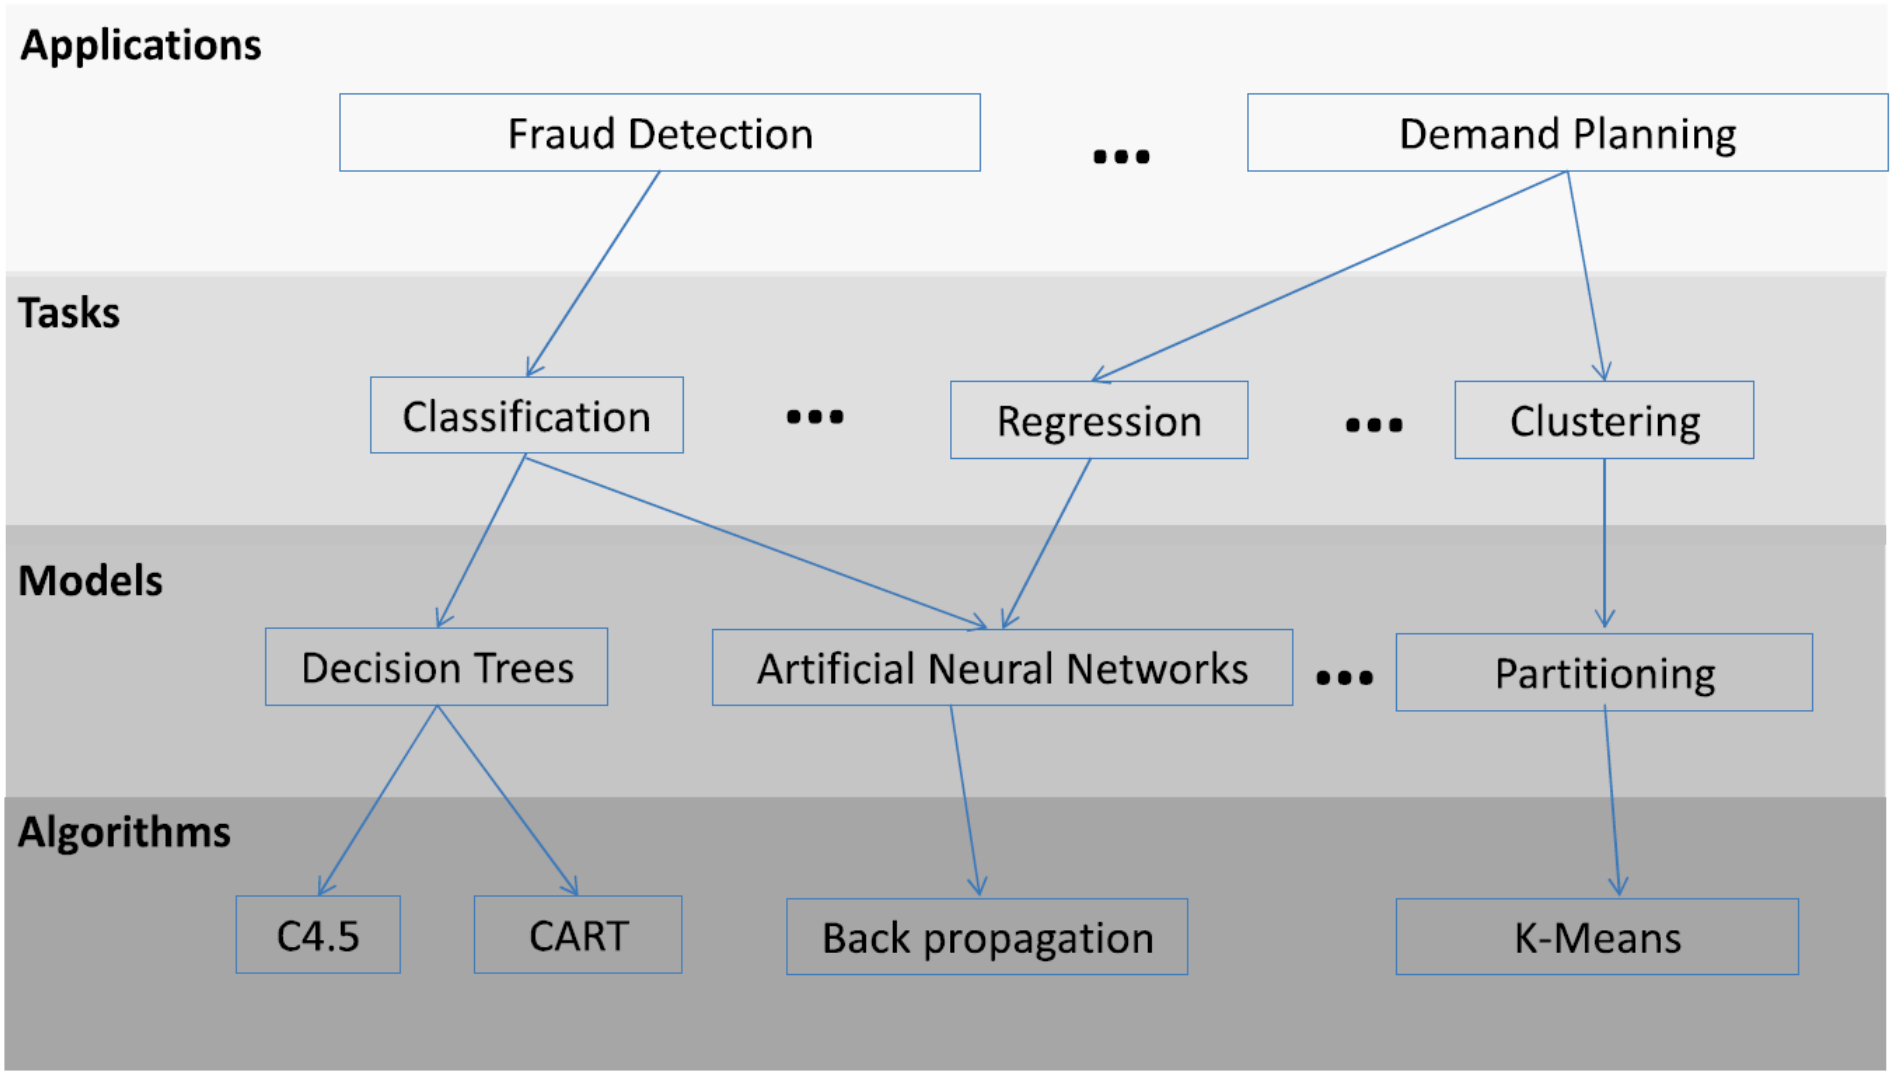


Pristupi, zadatci, primjene



https://vitalflux.com/great-mind-maps-for-learning-machine-learning/

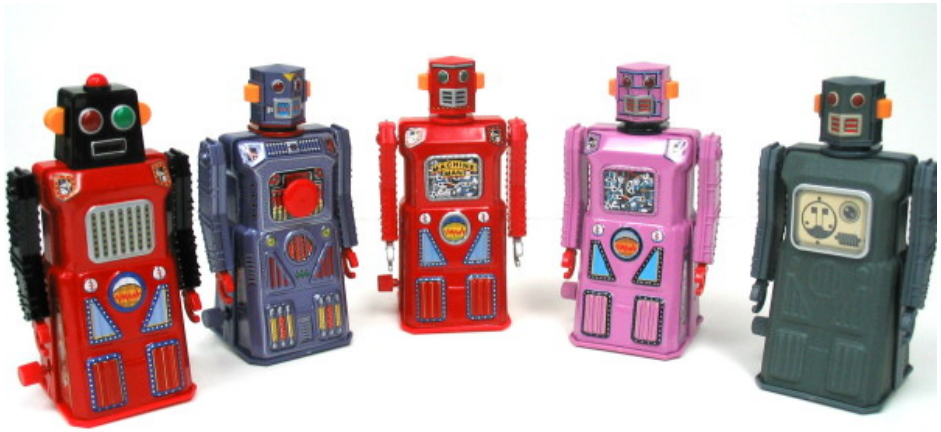
Primjene, zadatci, modeli i algoritmi



Rokach, L. and Maimon, O. Z. (2008). Data Mining with Decision Trees: Theory and Applications.

Pet škola strojnog učenja

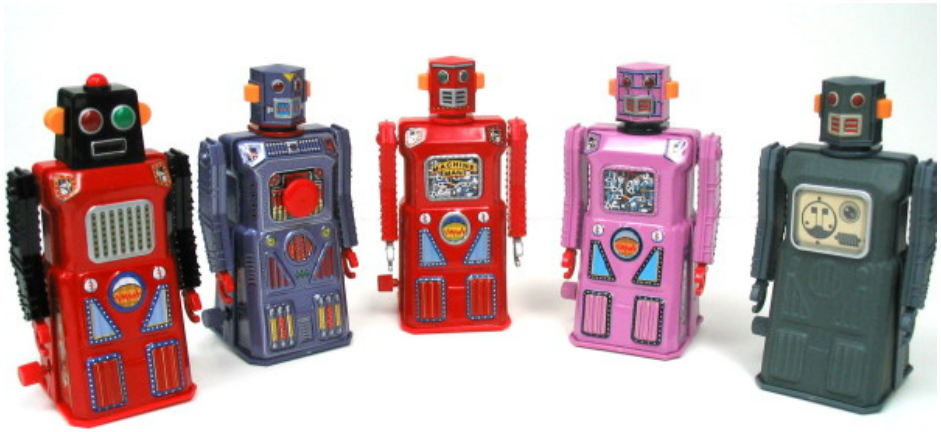
Pedro Domingos: The Master Algorithm



Škola	Temelji	Glavni algoritam
Symbolists	Logika, filozofija	Indukcija
Connectionists	Neuroznanost	Backpropagation
Evolutionaries	Evolucijska biologija	Genetičko programiranje
Bayesians	Statistika	Probabilističko zaključivanje
Analogizers	Psihologija	Jezgreni strojevi

Pet škola strojnog učenja

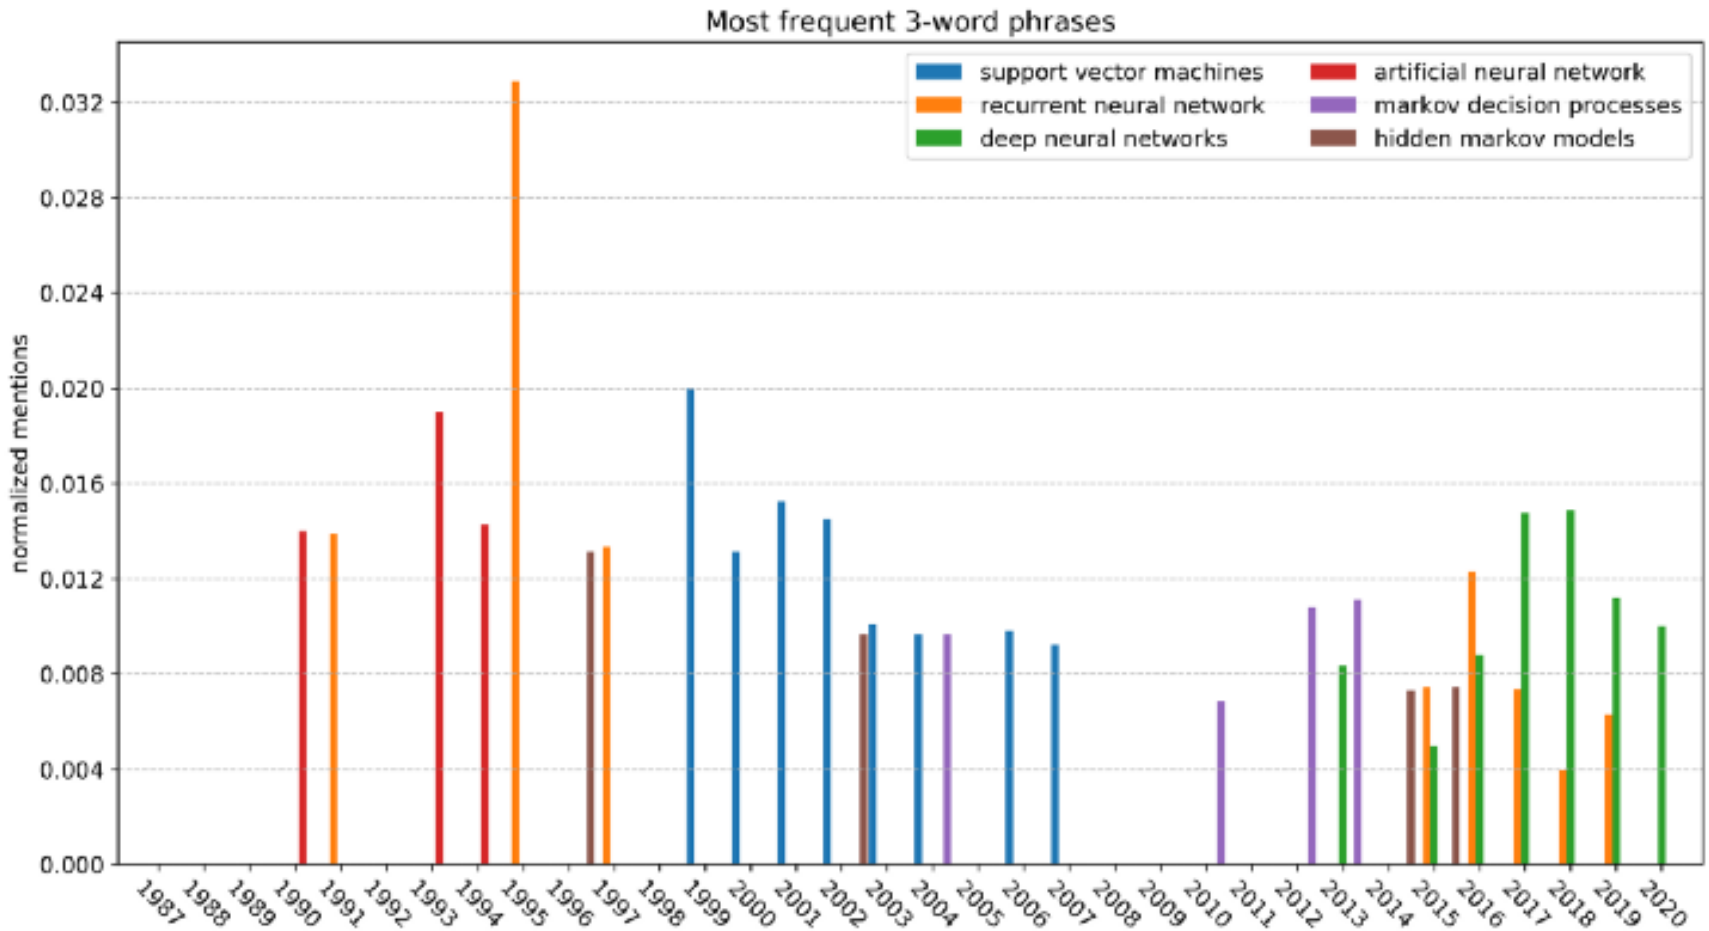
Pedro Domingos: The Master Algorithm



Škola	Cilj
Symbolists	Popunjavanje rupa u znanju
Connectionists	Emulacija mozga
Evolutionaries	Simulacija evolucije
Bayesians	Sustavno smanjivanje neizvjesnosti
Analogizers	Uočavanje sličnosti između staroga i novoga

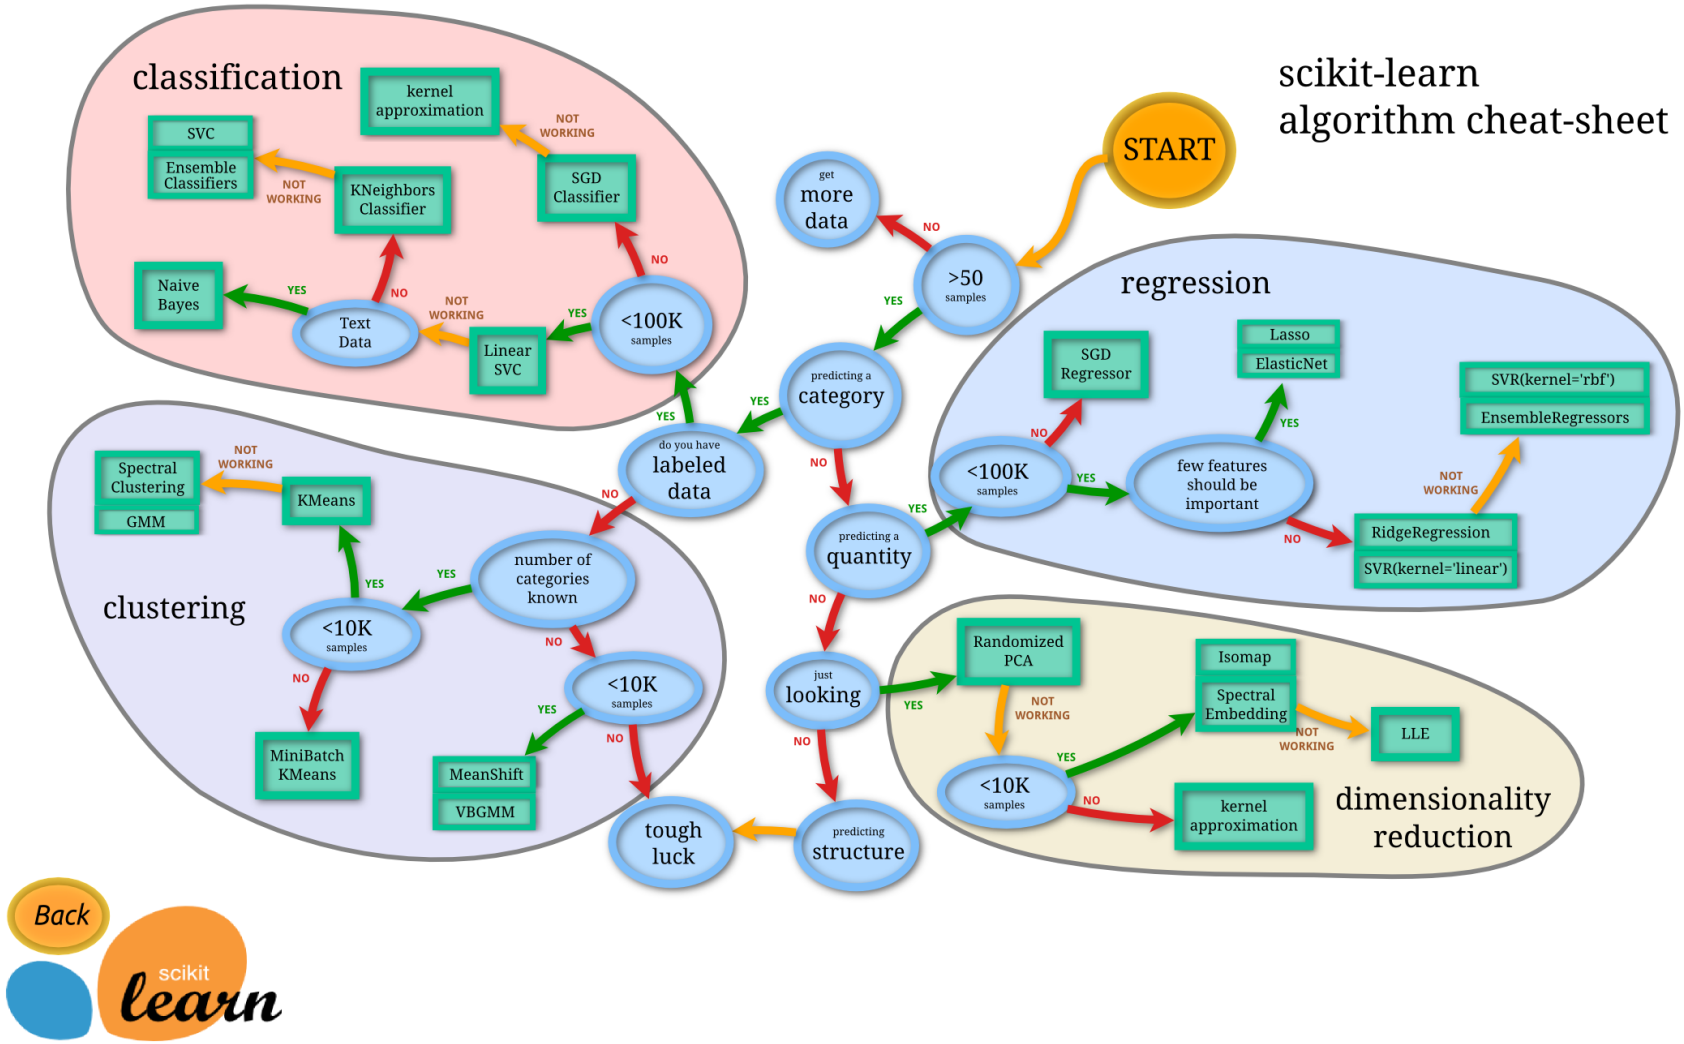
Trendovi

Najčešće fraze u radovima na konferenciji NeurIPS



https://towardsdatascience.com/neurips-conference-historical-data-analysis-e45f7641d232

Karta strojnog učenja



https://scikit-learn.org/stable/tutorial/machine_learning_map/

Još primjera...

Jupyter-bilježnica 1: Uvodni primjer
https://tinyurl.com/2s4j5x35

Svi primjeri dostupni su na:
https://github.com/jsnajder/StrojnoUcenje

Sažetak

- **Strojno učenje** bavi se rješavanjem problema koje je teško riješiti klasičnim UI pristupima
- Podataka ima u izobilju – izazov je transformirati podatke u **znanje** tako da možemo **zaključivati i predviđati**
- Strojno učenje povezano je sa statistikom, računarskom znanošću, umjetnom inteligencijom, ...
- Učenje se svodi na **optimizaciju parametara modela** na temelju **podataka**
- Dva osnovna pristupa: **nadzirano učenje** (zadatci klasifikacije i regresije) i **nenadzirano učenje** (zadatci grupiranja, procjene gustoće, smanjenje dimenzionalnosti)



Sljedeća tema: Osnovni koncepti

Sadržaj

1 Što i zašto?

2 Pristupi strojnom učenju

3 Organizacija predmeta

Izvođači

Predavači:

- Prof. dr. sc. Jan Šnajder
- Prof. dr. sc. Stjepan Picek
- Izv. prof. dr. sc. Marko Đurasević

Asistenti:

- Dr. sc. Josip Jukić (glavni asistent)
- Ana Barić, Ivan Bilić, Marko Čuljak, Karlo Koledić, Josipa Lipovac

Demosi:

- Alan Đurđević, Ana Vuksanović, Andrea Milanović, Dora Bilić-Pavlinović, Dunja Petrović, Filip Vučenik, Fran Širić, Hana Ivančić, Ivan Skukan, Jelena Lončar, Lana Barišić, Lana Ćorić, Petar Belošević, Vedran Ćutić, Vedran Knežević, Vinko Đurić

O predavačima



Prof. dr. sc. Jan Šnajder
http://www.zemris.fer.hr/~jan/

- Diplomirao (2002) i doktorirao (2010) računarsku znanost na FER-u
- Poslijedoktorski na Sveučilištu u Heidelbergu, znanstveno usavršavanje na Sveučilištu u Stuttgartu, NICT Kyoto i Sveučilištu u Melbourneu
- Istraživački interesi: obrada prirodnog jezika (NLP) i strojno učenje (neuronski NLP modeli, tekstna analitika, računalna društvena znanost)

O predavačima



Prof. dr. sc. Stjepan Picek
https://www.fer.unizg.hr/stjepan.picek

- Diplomirao (2008) elektrotehniku na Tehničkom fakultetu, Rijeka; doktorirao (2015) računarsku znanost na FERu i Radboud sveučilištu, Nizozemska; doktorirao (2024) matematiku na Sveučilištu Pariz 13, Francuska
- Poslijedoktorski na Sveučilištu Leuven, Belgija i MIT, SAD.
- Istraživački interesi: računalna sigurnost, kriptografija, strojno učenje, sigurnost strojnog učenja, algoritmi optimizacije

O predavačima



Izv. prof. dr. sc. Marko Đurasević
https://www.fer.unizg.hr/marko.djurasevic

- Diplomirao (2014) i doktorirao (2018) računarstvo na FER-u
- Znanstveno usavršavanje na Sveučilištu u Oviedu
- Istraživački interesi: evolucijski računarstvo, optimizacija i strojno učenje

Plan nastave

23 teme organizirane u 6 cjelina:

(1) Uvod u strojno učenje, Osnovni koncepti, Linearna regresija
(2) Linearni diskriminativni modeli, Logistička regresija
(3) Stroj potpornih vektora, Jezgrene metode, Neparametarske metode
(∗) Opcionalno: Ansambli

Međuispit

(4) Procjena parametara, Bayesov klasifikator
(5) Probabilistički grafički modeli
(6) Grupiranje, Vrednovanje modela
(∗) Opcionalno: Odabir značajki

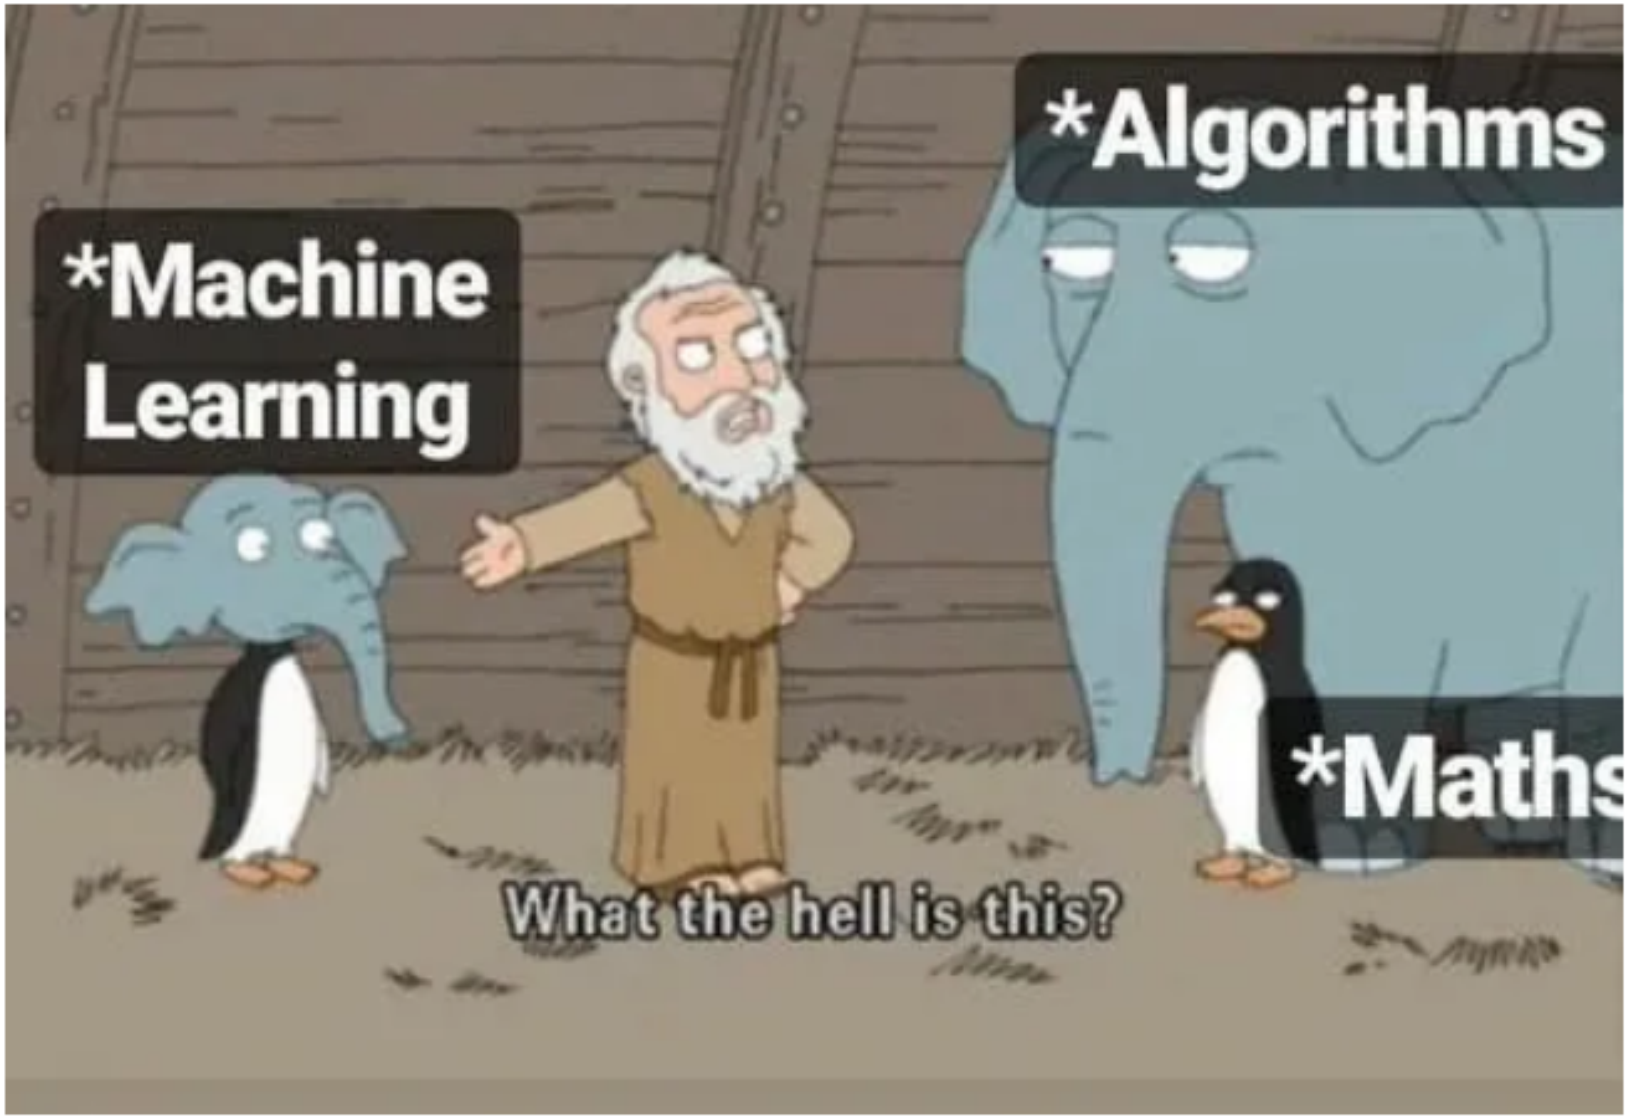
Završni ispit

Ishodi učenja

- Definirati osnovne pojmove strojnog učenja
- Objasniti teorijske pretpostavke, matematičke osnove te prednosti i nedostatke temeljnih algoritama (ne)nadziranog strojnog učenja
- Primijeniti temeljne algoritme klasifikacije, regresije i grupiranja na jednostavnije probleme
- Primijeniti postupak odabira i evaluacije točnosti modela
- Analizirati i usporediti temeljne algoritme strojnog učenja s obzirom na njihove komponente i računalnu složenost
- Razlikovati temeljne pristupe strojnom učenju (generativni/diskriminativni, parametarski/neparametarski, bayesovski/frekventistički) te objasniti poveznice
- Oblikovati i implementirati jednostavnije algoritme za klasifikaciju, regresiju i grupiranje

U konačnici, želimo da...

1. Razumijete **osnovne ideje** i **razine apstrakcije**
2. Razumijete tipičnu **matematiku** ispod toga
3. Shvatite **algoritme i metode** tako da ih implementirate ili ispitate na jednostavnim primjerima
4. Izgradite svoju **kartu područja** i dobijete **putokaze** za samostalno učenje



MATH + ALGORITHM = MACHINE LEARNING

Nastavne aktivnosti

Predavanja/vježbe:

- HR: ponedjeljkom 10–12 sati (M4) i srijedom 8–10 sati (M4)
- HR: ponedjeljkom 12–14 sati (A211) i srijedom 10–12 sati (M2)
- EN: ponedjeljkom 16–18 sati (A211) i srijedom 16–18 sati (A211)

Domaće zadaće:

- 6 zadaća koje predajete online

Laboratorijske vježbe:

- 4 vježbe koje predajete online pa demonstrirate asistentima

Konzultacije:

- Prof. dr. sc. Jan Šnajder: četvrtkom, 12–13 sati u D339A
- Prof. dr. sc. Stjepan Picek: po dogovoru, u D311
- Izv. .prof. dr. sc. Marko Đurasević: ponedjeljkom, 9–10 sati u D338
- Dr. sc. Josip Jukić: srijedom, 12–13 sati u D339A

Predavanja

- **20 predavanja** i **6 rekapitulacija**
- Klasična predavanja (ja objašnjavam na ploči, vi pratite, radite bilješke i pitate ako nešto nije jasno)
- Podijeljena u 6 cjelina, nakon svake cjeline radimo **rekapitulaciju** i rješavamo nekoliko zadatka s prošlogodišnjih ispita (aka auditorne vježbe)
- Kratka **kviz-pitanja** na satu (za motivaciju i formativnu povratnu informaciju), preko Moodlea, za ukupno najviše 6 bodova
- Preporučamo da dolazite na predavanja

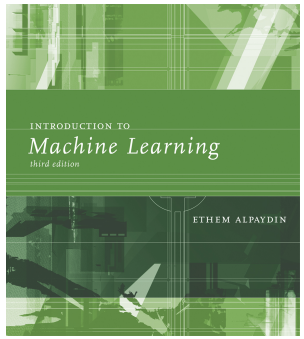
Materijali za učenje

1. Videopredavanja
2. Skripte s predavanja (tekst predavanja s primjerima, dodatnim bilješkama i literaturom za one koji žele znati više ☺)
3. Natuknice s predavanja (vrlo sažeta predavanja)
4. Zadatci za učenje i vježbu (uključivo zadatci s ispita)
5. Laboratorijske vježbe

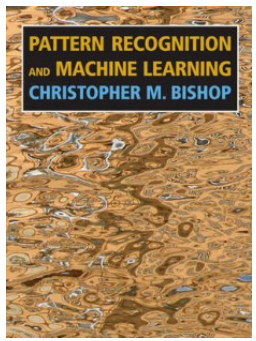
Sve je javno dostupno na
https://www.fer.unizg.hr/predmet/struce1/materijali

Dodatna literatura

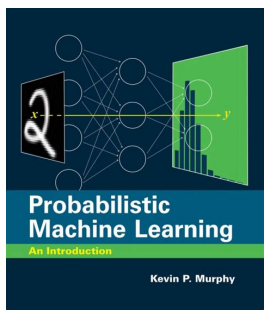
- Ethem Alpaydin:
  Introduction to Machine Learning,
  3rd edition, MIT Press, 2015.



- Christopher Bishop:
  Pattern Recognition and Machine Learning,
  Springer, 2006.



- NEW Kevin P. Murphy: *Probabilistic Machine Learning: An Introduction*, MIT Press, 2022.



Dodatna dodatna literatura

Osnovno:

- Hastie, Tibshirani, Friedman: *Elements of Statistical Learning: Data Mining, Inference, and Prediction*, Springer, 2003.
- Deisenroth, Faisal, Ong: *Mathematics for Machine Learning*. Cambridge University Press, 2020.
- Marsland: *Machine Learning: An Algorithmic Perspective*, Chapman and Hall/CRC, 2009.
- Duda, Hart, Stork: *Pattern Classification*, Wiley-Interscience, 2000.

Napredno:

- 

Murphy: *Probabilistic Machine Learning: Advanced Topics*, MIT Press, 2022.
- Mohri, Rostamizadeh, Talwalkar: *Foundations of Machine Learning*, MIT Press, 2012.
- Shalev-Shwartz, Ben-David: *Understanding machine learning: From theory to algorithms*, Cambridge University Press, 2014.

Specifično:

- Koller, Friedman: *Probabilistic Graphical Models: Principles and Techniques*, MIT Press, 2009.
- Goodfellow, Bengio, Courville:*Deep Learning*, MIT Press, 2016.

Domaće zadaće

- **6 domaćih zadaća**, radite ih nakon rekapitulacije
- Zadatci za vježbu koje rješavate rukom na papiru i uploadate rješenje na Moodle kao jedan PDF file
- Bodovanje: ukupno najviše 12 bodova za 6 zadaća
- Domaće zadaće usklađene su s **ishodima učenja** predmeta, dok ispiti provjeravaju te iste ishode učenja. To znači da, ako rješavate domaće zadaće, vjerojatno ćete dobro riješiti ispit
- Domaće zadaće trebate raditi **samostalno**

Laboratorijske vježbe

- **4 laboratorijske vježbe**, radite ih u Pythonu u okruženju **SciPy** korištenjem biblioteke **scikit-learn** i Jupyter-bilježnice
- Svrha vježbi je stecanje dubljeg razumijevanje rada algoritama. Svrha vježbi **nije** stjecanje iskustva rada na stvarnom projektu strojnog učenja (za to postoje drugi predmeti)
- Bodovanje: maks. 6 bodova po vježbi, ukupno najviše 24 bodova
- Rješenja **demonstrirate asistentima** u svom terminu laboratorijske vježbe
- Promjena termina moguća je jedino u parovima studenata; molimo, ne dolazite u druge termine (iznimka: slučaj više sile)
- Ako ste ponovno upisali predmet, laboratorijske vježbe trebate **predati ponovo** (možete predati svoja prošlogodišnja rješenja ili ih doraditi)

Laboratorijske vježbe

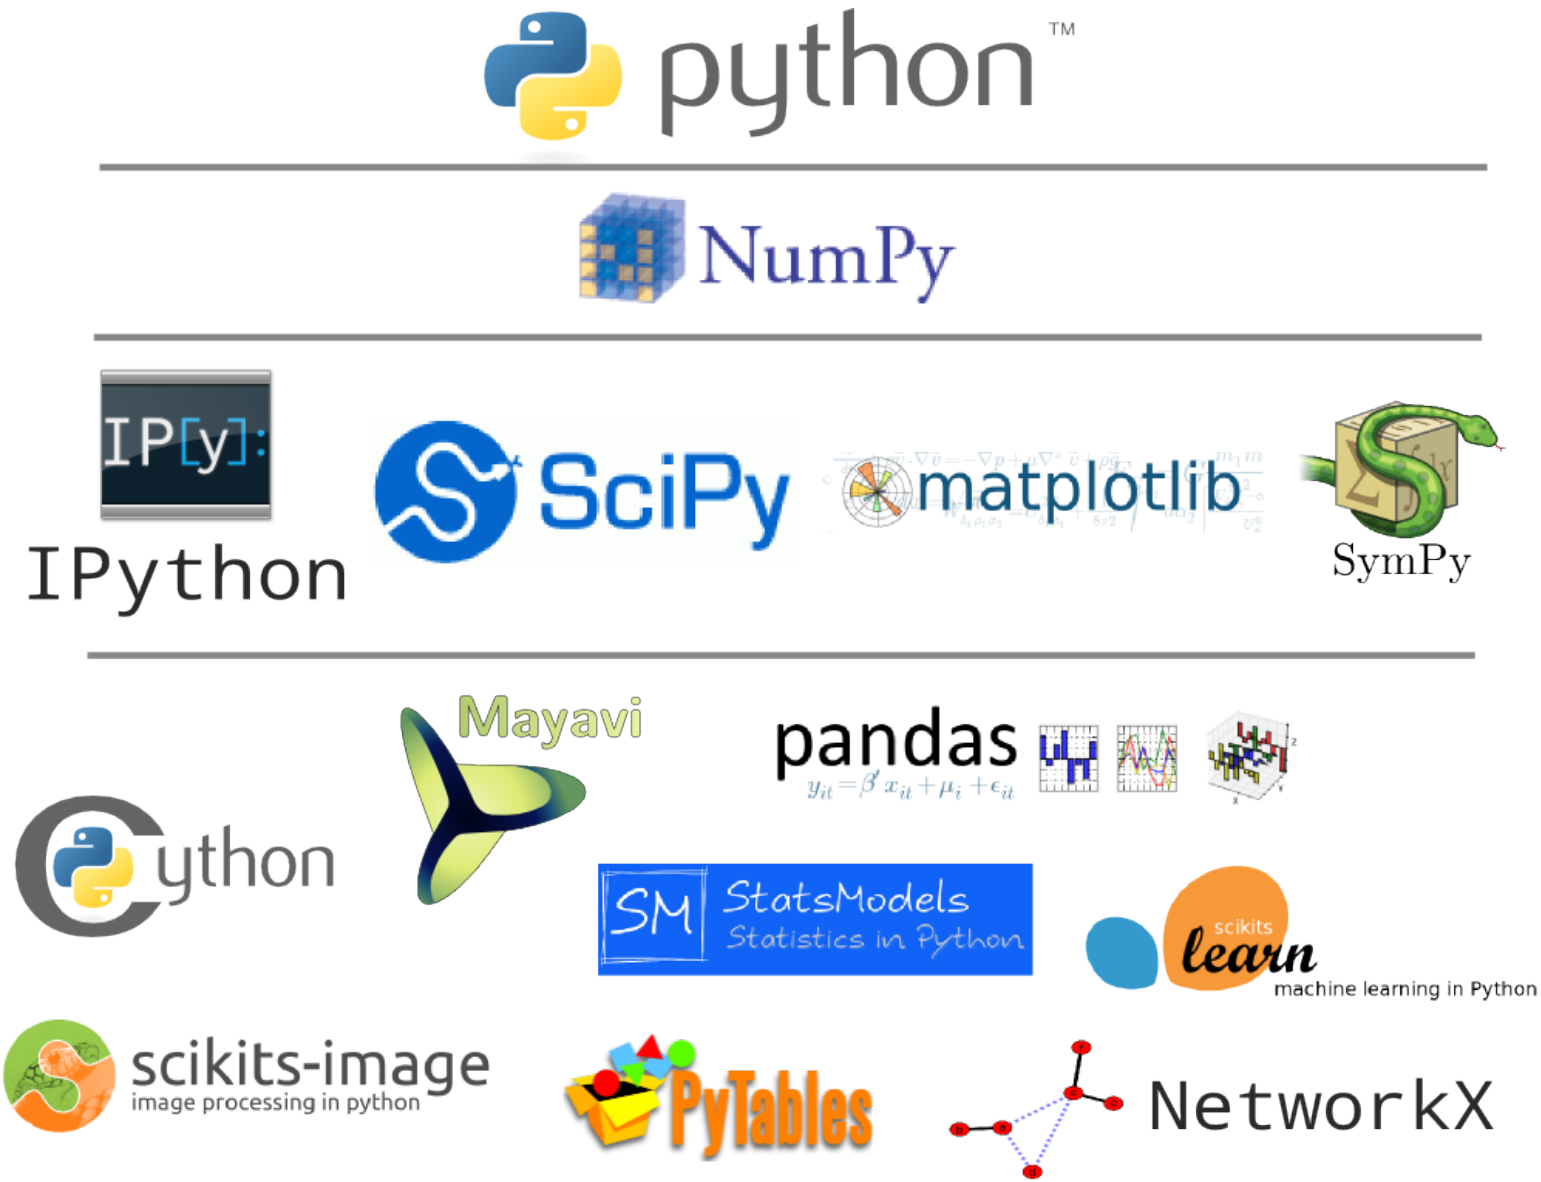
- Trebate biti sposobni na zahtjev **mijenjati programski kôd** te **razumijeti svu teoriju** na kojima se temelje modeli/algoritmi
- Demonstracija rješenja vježbe asistentima provodi se u dva modaliteta:
  - Osnovna provjera ($\sim$5 minuta)
  - Detaljna provjera ($\sim$15 minuta)
- Za svaku vašu predanu vježbu slučajnim će mehanizmom biti određen modalitet provjere; s modalitetom provjere upoznat će vas asistent neposredno prije vaše demonstracije
- Laboratorijske vježbe trebate raditi **samostalno**

Samostalan rad

Pravila samostalnog rada

1. Sve zadatke morate rješavate sami
2. Dozvoljeno je konzultirati se s drugim studentima prije rješavanja zadataka (navesti njihova imena)
3. Nije dozvoljeno koristiti programski kôd s Interneta
4. Nije dozvoljeno korištenje UI-asistenata za kodiranje (uključivo alata generativne UI, kao što je ChatGPT)
5. Ne smijete iskoristiti kôd ili dio kôda koji imate otprije, a niste ga radili potpuno samostalno
6. Povreda bilo kojeg od gornjih pravila smatra se predstavljanjem tuđega rada kao svojega (plagijat) te povlači uskraćivanje potvrde ispunjenja studijskih obaveza (nemogućnost polaganja predmeta u ovoj akademskoj godini) i prijavu Povjerenstvu za stegovnu odgovornost studenata

Ekosustav SciPy



Laboratorijske vježbe i domaće zadaće – savjeti

1. Krenite raditi na vrijeme.
2. Ne precjenjujte svoje sposobnosti. Nemojte krenuti raditi vježbu i zadaću tek na vikend uoči predaje.
3. Ako ipak niste stigli napraviti vježbu ili zadaću, nemojte je prepisati i takvu predati. Umjesto toga, naučite nešto iz toga i drugi puta krenite ranije.
4. Uračunajte nepredvidive okolnosti. Možda nešto neće raditi isprve, ili će vam trebati više vremena da nešto shvatite. Ako si ostavite dovoljno vremena za takve situacije, izbjeći ćete stres.
5. Ponovite teorijske osnove iza svake lab. vježbe. Svrha laboratorijskih zadataka je upravo da povežu teoriju s praksom. Asistenti će vas zato pitati i teoriju iza svakog zadatka.
6. Proučite **nultu laboratorijsku vježbu**, premda se ne predaje, pa čak i ako (mislite da) ste jako dobri u Pythonu.

Laboratorijske vježbe – izostanak

- Na vježbe morate doći u terminu koji vam je dodijeljen
- Možete pokušati zamijeniti svoj termin preko burze grupa na FERwebu, i to prije roka za predaju vježbe
- Iznimno, možete doći u drugi termin bez zamjene i bez prethodne najave, ali...
  - to možete učiniti samo jednom (asistenti će voditi evidenciju)
  - svoje rješenje ćete moći demonstrirati samo ako je preostalo dovoljno vremena nakon što asistenti ispitali sve studente iz dotičnog termina
  - ako ima više studenata nego što je preostalo vremena, asistenti će nasumično odabrati koga će ispitati
  - imajte na umu da možda nećete stići demonstrirati rješenje, stoga je sigurnije držati se svog termina

Laboratorijske vježbe – izostanak zbog više sile

- Ako ne možete doći u svoj termin vježbi zbog više sile, molimo slijedite ovaj protokol:
  1. preskočite svoj termin
  2. nema potrebe da nas kontaktirate
  3. nakon što se situacija sredi, dođite do nas u uredovno vrijeme
  4. zajedno ćemo razraditi plan za nadoknadu vježbe

Ispit

- Ispit provjerava **ishode učenja**
- Ispit se sastoji od **pismenog ispita** i **usmenog ispita**
- Za pozitivnu ocjenu na predmetu potrebno je položiti oba dijela ispita
- Za pismeni ispit postoje dvije opcije:
  - Kontinuirano: međuispit + završni ispit
  - Ispitni rok
- U oba slučaja potrebno je položiti i usmeni ispit

Pismeni ispit

- Ispit je u obliku **pitanja s ponuđenim odgovorima** (teorijska, problemska i numerička pitanja)
- Ukupno 20 pitanja; za 100% bodova dovoljno je točno riješiti njih 18
- Točan odgovor nosi $+1$ bod, a netočan $-1/3$ boda
- Vrednuju se isključivo odgovori naznačeni na ispitnom obrascu
- Obavezni ste predati papire na kojima je jasno vidljiv vaš postupak rješavanja svih pitanja na koje ste na ispitu odgovorili (ako to ne predate, ispit će vam biti poništen)
- Trajanje ispita je 150 minuta
- Čuvari na ispitu ne smiju odgovarati na pitanja o ispitnim pitanjima
- Svi primjerci prošlogodišnjih ispita dostupni su na stranici predmeta

Usmeni ispit

- Usmenom ispitu pristupaju isključivo studenti s pozitivno ocijenjenim pismenim ispitom (ostvaren prag bodova na pismenom ispitu)
- Usmeni ispit održava se nakon pismenog ispita u terminu koji će biti pravodobno objavljen
- Usmeni ispit može biti ocijenjen:
  - ✓ Pozitivno
  - **X** Negativno

- U pravilu, studenti koji na predmetu ostvare visok broj bodova bit će oslobođeni polaganja usmenog ispita

Elementi ocjene

	MI+ZI		Ispitni rok	
	Prag	Udio	Prag	Udio
Domaće zadaće		12%		12%
Kvizovi na satu				
Laboratorijske vježbe	25%	24%	25%	24%
Međuispit	50%	32%		
Završni ispit		32%		
Pismeni ispit			50%	64%
Usmeni ispit	100%		100%	

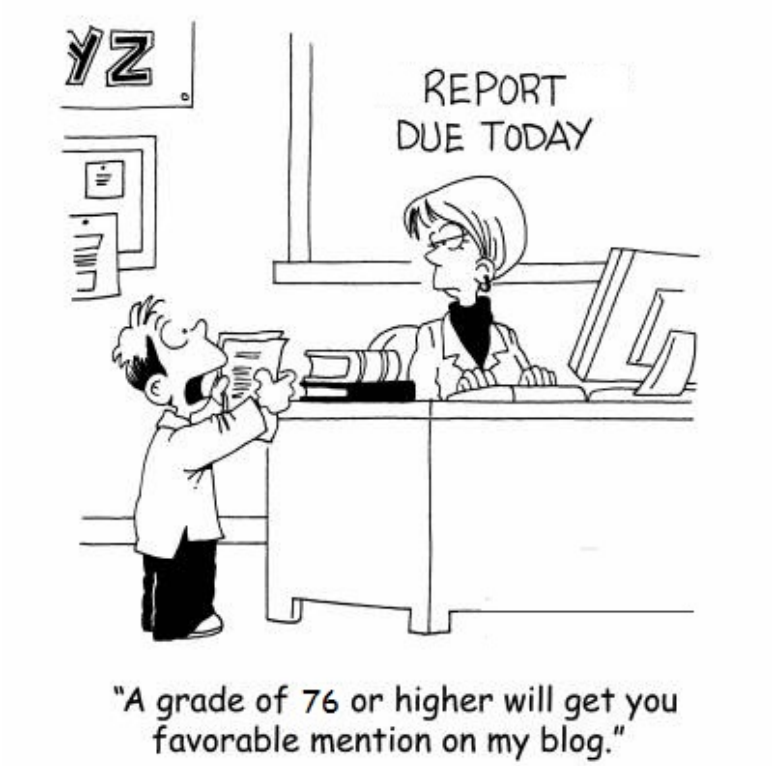
- Domaće zadaće ukupno nose 12 bodova, kvizovi ukupno nose 6 bodova, ali ove dvije aktivnosti u zbroju nose najviše 12 bodova
- Prag na lab. vježbama je 6 bodova (25% od 24 boda)
- Prag na ispitima je 32 boda na MI+ZI (50% od 32+32 bodova) ili 32 boda na ispitu (50% od 64 boda)
- Bodovi unutar svake aktivnosti zaokružuju se na 2 decimale

Uvjeti polaganja predmeta

Za pozitivnu konačnu ocjenu na predmetu potrebno je:

1. Ispuniti studijske obaveze na predmetu
2. Ostvariti sve bodovne pragove na laboratorijskim vježbama i ispitima
3. Ostvariti ukupno najmanje 50.00 bodova
4. Ostvariti pozitivnu ocjenu na usmenom ispitu

Konačna ocjena



00.00 – 49.99	Nedovoljan (1)
50.00 – 62.99	Dovoljan (2)
63.00 – 75.99	Dobar (3)
76.00 – 88.99	Vrlo dobar (4)
89.00 – 100.00	Izvrstan (5)

Ukupni bodovi zaokružuju se isključivo na 2 decimale.

Statistika uspjeha studenata

SU1, ak. god. 2023./2024., $N = 288$ – Deskriptivna statistika

	MIZI	ROK	OCJENA
count	233.000000	117.000000	242.000000
mean	36.580622	30.073846	3.309917
std	11.489616	10.600373	0.941783
min	9.030000	0.000000	2.000000
25%	28.050000	25.020000	3.000000
50%	35.550000	32.010000	3.000000
75%	45.030000	37.020000	4.000000
max	60.000000	51.030000	5.000000

Ocjena:

	count	mean	std	min	25%	50%	75%	max
CONT								
0	76.0	2.776316	0.665306	2.0	2.0	3.0	3.0	4.0
1	166.0	3.554217	0.950317	2.0	3.0	4.0	4.0	5.0

Statistika uspjeha studenata

SU1, ak. god. 2023./2024., $N = 288$ – Regresijska analiza

OLS Regression Results

Dep. Variable:	ISPIT	R-squared:	0.295
Model:	OLS	Adj. R-squared:	0.287
Method:	Least Squares	F-statistic:	39.53
Date:	Sun, 28 Sep 2025	Prob (F-statistic):	2.23e-21
Time:	21:47:43	Log-Likelihood:	-1049.0
No. Observations:	288	AIC:	2106.
Df Residuals:	284	BIC:	2121.
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	11.0841	2.772	3.998	0.000	5.627	16.541
LABOS	0.8811	0.124	7.124	0.000	0.638	1.125
DZ	0.4922	0.202	2.441	0.015	0.095	0.889
KVIZ	0.4517	0.201	2.250	0.025	0.057	0.847

Omnibus:	4.756	Durbin-Watson:	1.914
Prob(Omnibus):	0.093	Jarque-Bera (JB):	4.598
Skew:	-0.238	Prob(JB):	0.100
Kurtosis:	3.397	Cond. No.	133.

Komunikacija

- Molimo koristite kontaktni obrazac na https://forms.gle/QnhVyUxthLALfC4b6
- Ako vaš problem nije pokriven kontaktnim obrascem, dođite do nas

Molimo, ne šaljite mejlove!

Zbog velikog broja studenata upisanih na predmet, **tijekom zimskog semestra** nismo u mogućnosti odgovarati na mejlove u vezi s predmetom. Molimo, koristite kontaktni obrazac. Ako imate bilo kakvih nejasnoća u vezi gradiva ili ako trebate pomoć s lab. vježbama, dođite do nas u uredovno vrijeme. Nakon isteka zimskog semestra ponovno nas **možete kontaktirati mejlom** u vezi s predmetom.

Rasprava o međuispitu/završnom ispitu

- Nakon međuispita i nakon završnog ispita provest ćemo upitnik o ispitu
- Nakon toga organizirat ćemo **sastanak** na kojima ćemo sa zainteresiranim studentima raspraviti rezultate ispita i eventualne intervencije, ako su opravdane

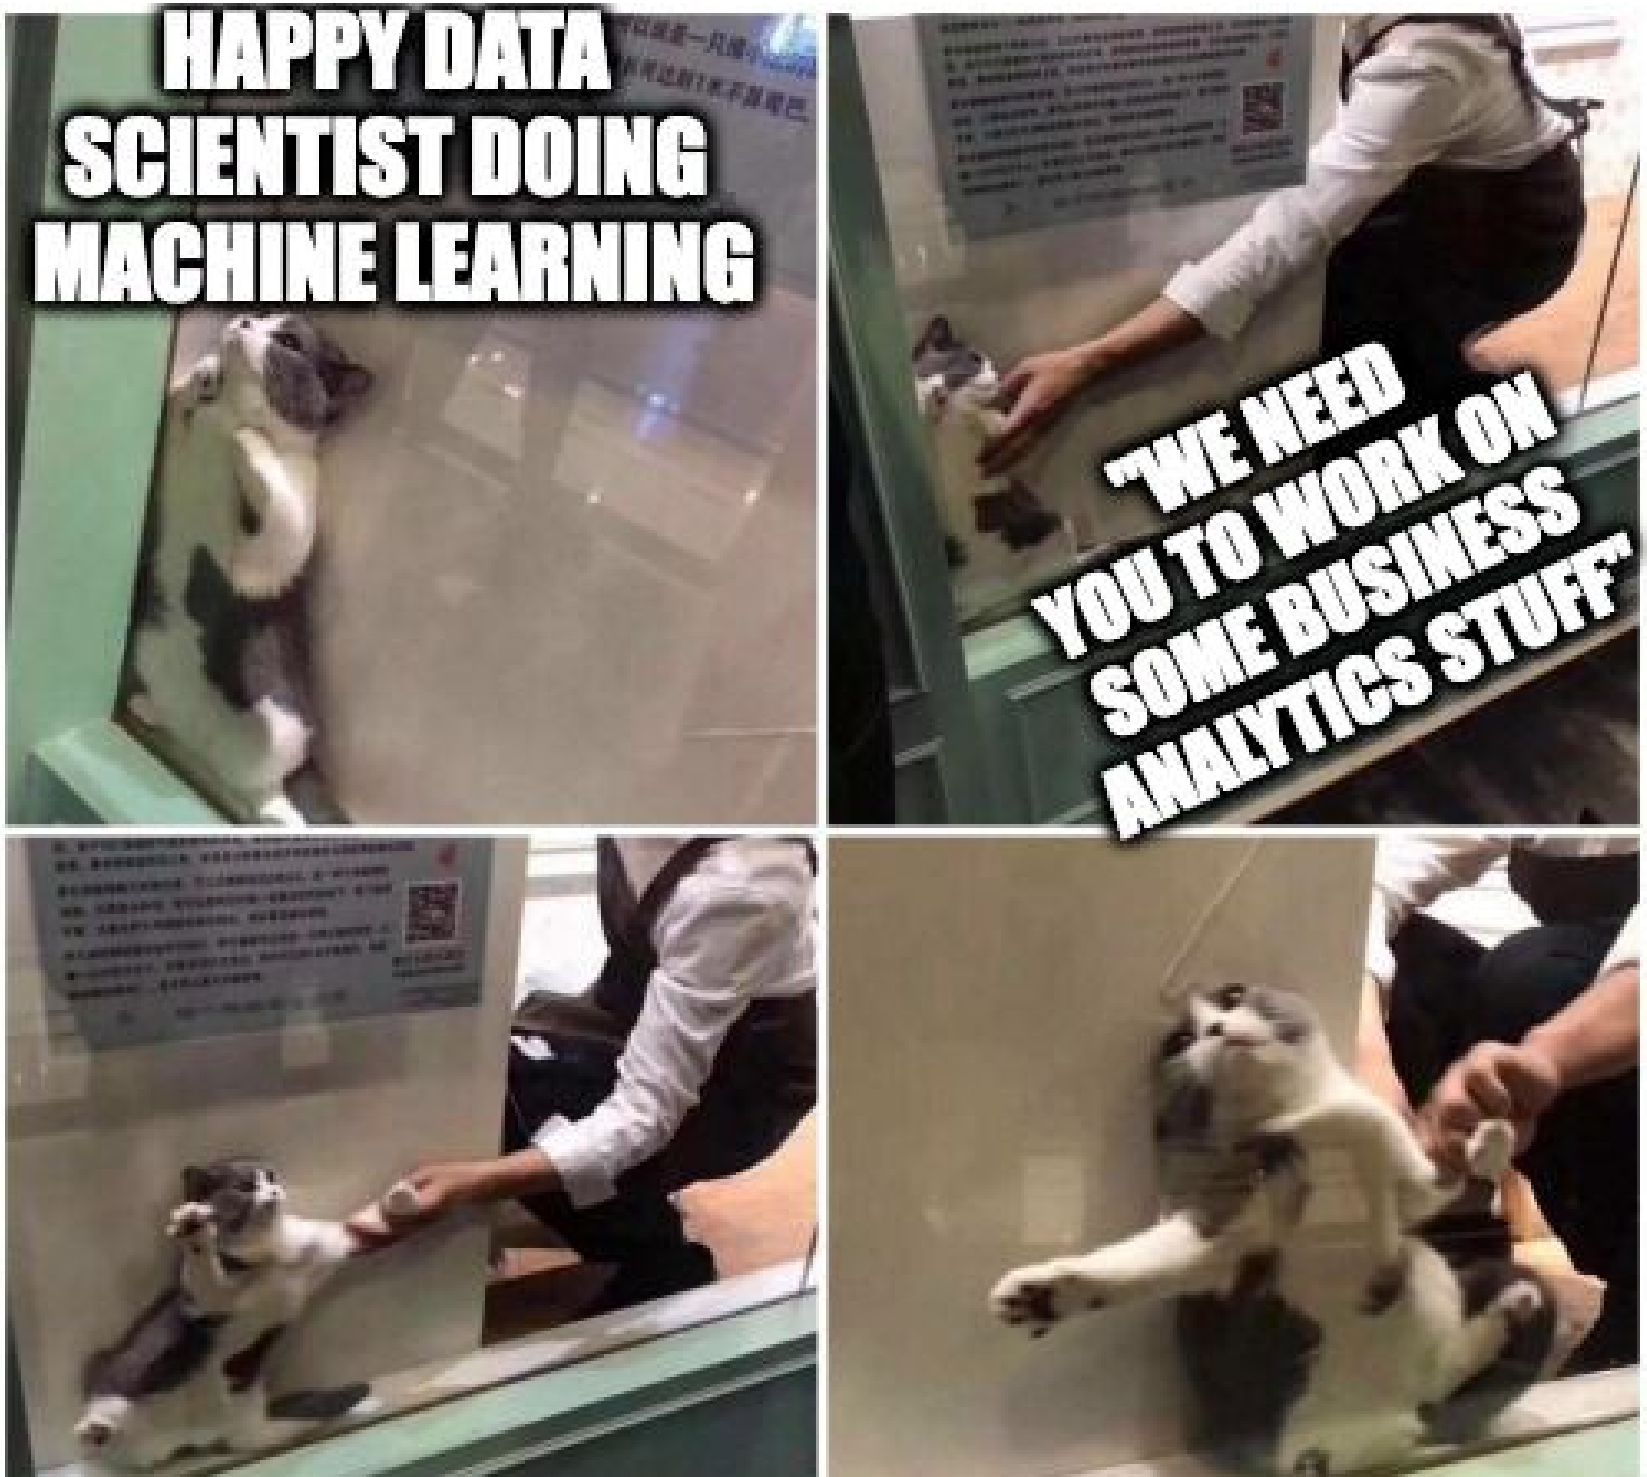
U slučaju poteškoća ili nedoumica

Ako imate poteškoća sa studiranjem (probleme koje ne možete riješiti sami ili za koje trebate savjet), možete se javiti **Savjetničkoj službi FER-a**: www.fer.unizg.hr/zivot_na_fer-u/zdravlje_i_dobrobit/savjetnicka_sluzba

Ako su problemi povezani s ovim predmetom, dođite na konzultacije.

Web-stranica predmeta i materijali

- https://www.fer.unizg.hr/predmet/struce1
- https://www.fer.unizg.hr/predmet/struce1/obavijesti
- https://www.fer.unizg.hr/predmet/struce1/materijali
  - Kalendar predmeta
  - Ishodi učenja (detaljno za svaku od 23 teme)
  - Pitanja i odgovori (+ poveznica na kontakt-obrazac)
  - Videopredavanja (za 18 tema)
  - Predavanja (skripte, za 18 tema)
  - Natuknice za predavanja
  - Zadatci za vježbu
  - Laboratorijske vježbe
  - Prošlogodišnji ispiti


HAPPY DATA SCIENTIST DOING MACHINE LEARNING
"WE NEED YOU TO WORK ON SOME BUSINESS ANALYTICS STUFF"